



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE TECNOLOGIA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA
MECATRÔNICA



Projeto de Controlador PID para Sistemas de Segunda Ordem com Atraso via Resposta em Frequência

Jhonat Heberson Avelino de Souza

Orientador: Prof. Dr. Carlos Eduardo Trabuco Dórea

Co-orientador: Prof. Dr. José Mário Araújo

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Mecatrônica da UFRN como parte dos requisitos para obtenção do título de Mestre em Ciências.

Número de ordem PEM: M018

Natal, RN, julho de 2022

Resumo

Fenômenos como vibrações mecânicas, ressonância e oscilações, podem ser descritos matematicamente por sistemas de equações diferenciais de segunda ordem, sendo estes sistemas comumente designados como sistemas de segunda ordem. Trabalhar com esse tipo de modelo, em vez dos modelos de estado de primeira ordem, traz benefícios numéricos, mas há dificuldades inerentes à determinação de seus parâmetros físicos. Os desafios são ainda mais significativos quando se considera a existência de atrasos entre as medições dos estados e os sinais de atuação, levando algumas abordagens à necessidade de uma pós-análise para determinar a estabilidade das soluções calculadas. Uma alternativa para contornar as dificuldades de medição de parâmetros é a abordagem por resposta em frequência que usa modelos baseados em receptância. É reconhecido na literatura que modelos mais precisos de receptância podem ser obtidos experimentalmente quando comparados aos modelos por equações diferenciais. Além disso, os modelos de receptância permitem tratar o atraso de forma explícita, sem recorrer a aproximações. Otimização via Algoritmo Genético é usada para determinar os ganhos do controlador. O objetivo deste trabalho é desenvolver um método baseado em receptância para o rastreamento robusto de referências de sistemas de segunda ordem com atraso representados por receptância, usando controladores do tipo PID - Proporcional-Integral-Derivativo. A ação integral deste controlador garante o rastreamento de referências constantes, desde que o sistema em malha fechada seja estável. As condições de robustez e a busca via otimizações descritas anteriormente devem, assim, ser estendidas a esse tipo de controlador. Devem ser analisados tanto o caso monovariável quanto o de sistemas com múltiplas entradas e saídas. A eficácia da técnica deve ser avaliada por meio de simulações numéricas, usando modelos disponíveis na literatura.

Palavras-chave: Sistemas de Segunda Ordem, Sistemas com Atraso, Matriz de Receptância, Algoritmo Genético.

Abstract

Phenomena such as mechanical vibrations, resonance and oscillations can be mathematically described by systems of differential equations of second order, and these systems are commonly referred to as second order. Working with this type of model, instead of the state-of-the-art models first order, brings numerical benefits, but there are difficulties inherent to the determination of its physical parameters. The challenges are even more significant when considering the existence of delays between state measurements and actuation signals, taking some approaches to the need for a post-analysis to determine the stability of the calculated solutions. An alternative to circumvent the difficulties of measuring parameters is the frequency response approach that uses models based on receptivity. It is recognized in the literature that more accurate models of receptivity can be obtained experimentally when compared to models by differential equations. In addition, the receptivity models allow to treat the delay explicitly, without resorting to approximations. Optimization via Genetic Algorithm is used to determine controller gains. The objective of this work is to develop a method based on receptivity for robust reference tracking of second-order systems with delay represented by receptivity, using controllers of the type PID - Proportional-Integral-Derivative. The full action of this controller ensures tracking of constant references as long as the closed loop system is stable. The strength conditions and the search via optimizations described above should, therefore, be extended to this type of controller. Both the case must be analyzed monovariable and systems with multiple inputs and outputs. THE The effectiveness of the technique must be evaluated through numerical simulations, using models available in the literature.

Keywords: Second Order Systems, Delayed Systems, Receptance Matrix, Genetic Algorithm.

Sumário

Sumário	i
Lista de Figuras	iii
Lista de Tabelas	v
Lista de Símbolos e Abreviaturas	vii
1 Introdução	1
2 Teoria	3
2.1 Sistemas de Segunda Ordem	3
2.1.1 Representação de Primeira Ordem	4
2.1.2 O Método da Receptância	5
2.1.3 A Matriz de Receptância	5
2.1.4 Sistema com Atraso	6
2.2 Resposta em Frequência	7
2.2.1 O Diagrama Polar, ou Diagrama de Nyquist	7
2.2.2 Critério de Estabilidade de Nyquist	8
2.3 Controlador Proporcional Integrativo Derivativo	10
2.4 Índices de desempenho	11
2.5 Robustez de Estabilidade	12
2.6 Sistemas Multivariáveis	13
3 Formulação do Problema	15
3.1 Parâmetro de Projeto e Formulação Matemática	16
3.2 Otimização de Desempenho	18
3.3 Abordagem para sistemas instáveis	19
4 Implementação do Método Proposto	21
4.1 Solução do Problema de Otimização	21
4.2 Problemas na implementação	24
4.3 A Função Robustez	25
4.4 A Função de Restrições	28
4.5 A Função de <i>IAE</i>	28
4.6 A Função de <i>Fitness</i>	30
4.7 A Função de Variabilidade	31

5	Experimentos e Resultados	33
5.1	Experimentos estudados	33
5.1.1	Exemplo 1	33
5.1.2	Exemplo 2	34
5.1.3	Exemplo 3	34
5.2	Resultados da Otimização de Robustez	35
5.2.1	Resultado exemplo 1	35
5.2.2	Resultado exemplo 2	36
5.2.3	Resultado exemplo 3	37
5.3	Resultados da Otimização de IAE	37
5.3.1	Resultado exemplo 1	37
5.3.2	Resultado exemplo 2	39
5.3.3	Resultado exemplo 3	40
5.4	Resultados da Comparação entre os parâmetros de otimização	42
5.4.1	Resultado exemplo 1	42
5.4.2	Resultado exemplo 2	42
5.4.3	Resultado exemplo 3	43
5.5	Resultados da Concorrência entre os parâmetros de otimização	44
5.5.1	Resultado exemplo 1	46
5.5.2	Resultado exemplo 2	46
5.5.3	Resultado exemplo 3	47
6	Conclusão	51
	Referências bibliográficas	52

Lista de Figuras

2.1	Sistema Massa-Mola-Amortecedor	3
2.2	Exemplo de Diagrama de Nyquist para Sistema modelado por $G(s)$	8
2.3	Diagrama de Nyquist com a Parte Espelhada	9
2.4	Diagrama de blocos do PID	10
2.5	Sistema multivariável	13
3.1	Diagrama de Nyquist Exemplo de Circunferência. M_s	17
3.2	Diagrama de Nyquist de um Sistema Genérico para Exemplo de um Caso de Instabilidade.	18
4.1	<i>Nyquist</i> com visão do sistema estável	26
4.2	<i>Nyquist</i> com visão do sistema instável	26
4.3	Simulação criada com MATLAB/Simulink®	30
5.1	Sistema massa-mola-amortecedor de um grau de liberdade	34
5.2	Diagrama de Nyquist Exemplo 5.1.1	35
5.3	Simulação do Sistema do Exemplo 5.1.1	36
5.4	Diagrama de Nyquist Exemplo 5.1.2	36
5.5	Simulação do Sistema do Exemplo 5.1.2	37
5.6	Diagrama de Nyquist Exemplo 5.1.3	38
5.7	Simulação do Sistema do Exemplo 5.1.3	38
5.8	Diagrama de Nyquist Exemplo 5.1.1	39
5.9	Simulação do Sistema do Exemplo 5.1.1	39
5.10	Diagrama de Nyquist Exemplo 5.1.2	40
5.11	Simulação do Sistema do Exemplo 5.1.2	40
5.12	Diagrama de Nyquist Exemplo 5.1.3	41
5.13	Simulação do Sistema do Exemplo 5.1.3	41
5.14	Comparação do diagrama de <i>Nyquist</i> do Exemplo 5.1.1	43
5.15	Comparação da simulação do Sistema do Exemplo 5.1.1	43
5.16	Comparação do diagrama de <i>Nyquist</i> do Exemplo 5.1.2	44
5.17	Comparação da simulação do Sistema do Exemplo 5.1.2	44
5.18	Comparação do diagrama de <i>Nyquist</i> do Exemplo 5.1.3	45
5.19	Comparação da simulação do Sistema do Exemplo 5.1.3	45
5.20	Diagrama de <i>Nyquist</i> com Método proposto do Exemplo 5.1.1	46
5.21	Simulação do Sistema com Método proposto do Exemplo 5.1.1	47
5.22	Diagrama de <i>Nyquist</i> com Método proposto do Exemplo 5.1.2	47
5.23	Simulação do Sistema com Método proposto do Exemplo 5.1.2	48

5.24	Diagrama de <i>Nyquist</i> com Método proposto do Exemplo 5.1.3	48
5.25	Simulação do Sistema com Método proposto do Exemplo 5.1.3	49

Lista de Tabelas

5.1	Tabela de Ganhos do PID - Otimização de Robustez	35
5.2	Tabela de Ganhos do PID - Otimização de <i>IAE</i>	38
5.3	Tabela de Variança dos Ganhos do PID - Comparação da Otimização de <i>IAE</i> com robustez	42
5.4	Tabela de Ganhos do PID com Método proposto - Comparação da Otimização de <i>IAE</i> com robustez	46

Lista de Símbolos e Abreviaturas

GM	<i>"gain margin"</i> , veja equação (3.11), página 19
PM	<i>"phase margin"</i> , veja equação (3.11), página 19
SISO	Single Input Single Output, veja equação (2.4), página 4
SPD	Semiplano Direito, veja equação (2.23), página 9
SPE	Semiplano Esquerdo, veja equação (2.22), página 8

Capítulo 1

Introdução

Fenômenos físicos como ressonâncias em sistemas vibratórios, oscilações em redes elétricas, vibro-acústica e muitos outros possuem métodos matemáticos para representar seus modelos (BALAS 1982, VANDERVELDE 1986). Muitas vezes, a descrição destes fenômenos é feita por meio de equações diferenciais de segunda ordem, que classificam tais sistemas como sistemas de segunda ordem.

Modelos matemáticos que representam esses sistemas podem ser escritos em sua forma bruta, como um sistema matricial de equações diferenciais de segunda ordem, onde as constantes e variáveis das equações têm relações físicas diretas com o modelo real, ou transformadas em equações diferenciais de primeira ordem. Em (DATTA 2004), são apresentadas representações de primeira ordem para alguns sistemas de segunda ordem e discutidas algumas deficiências associadas ao modelo original.

Devido à sua relevância prática, o estudo de sistemas de segunda ordem tem ganhado cada vez mais notoriedade na comunidade de engenharia, e proporcionando soluções para diversos desafios. Uma das dificuldades na utilização de modelos matemáticos obtidos a partir de equações diferenciais de segunda ordem está na definição dos elementos das matrizes que caracterizam o sistema, como massa e elasticidade. O conceito de matriz de suscetibilidade proposto em (MOTTERSHEAD e RAM 2007) permite modelos obtidos experimentalmente do sistema e tem sido utilizada em diversos trabalhos relacionados (ARAÚJO 2018, ARAÚJO e SANTOS 2018, LIU e YUAN 2016, SANTOS et al. 2018). Os métodos receptivos têm se mostrado muito benéfico no controle de sistemas com grande número de graus de liberdade e estruturas complexas (MOTTERSHEAD e RAM 2007).

Inspirado na possibilidade de medir experimentalmente modelos de sistemas de segunda ordem, demonstrada pela eliminação da necessidade de aproximações de atraso, o presente trabalho pretende principal propor métodos para resolver problemas de controle via realimentação de estado. Ao definir matematicamente o problema de controle como um problema de otimização dos ganhos do controlador, o algoritmo genético é utilizado como ferramenta de solução projetada para atender às especificações de projeto que garantem uma solução robusta para que o sistema permaneça estável mesmo sob influência de alterações de parâmetros.

Este trabalho apresenta uma estrutura robusta para projetar controlador Proporcional Integrativo Derivativo (PID) para sistemas de segunda ordem com atrasos. A ação inte-

gral é usado para obter o erro de rastreamento do ponto de ajuste nulo na presença de perturbação constante que possibilita graus de liberdade para aumentar a flexibilidade do projeto. As ações derivativa e proporcional são usados para lidar com problemas de retorno do sistema (GONTIJO et al. 2022). A metodologia de projeto é baseada em critério de estabilidade, de Nyquist como base teórica para obtenção dos valores dos ganhos do controlador que estabilize a planta e atenda aos requisitos do projeto de controle.

O trabalho está disposto da seguinte maneira:

- Capítulo 2: Apresenta a teoria matemática básica para a compreensão do problema abordado e desenvolvimento do trabalho.
- Capítulo 3: Apresenta o problema com equacionamento matemático e detalhes importantes sobre as vantagens do método a ser utilizado.
- Capítulo 6: Traz comentários conclusivos e sugestões para futuros trabalhos relacionados.

Capítulo 2

Teoria

2.1 Sistemas de Segunda Ordem

Diferentes tipos de sistemas, como os sistemas vibratórios mecânicos, são classificados como sistemas de segunda ordem. Esses sistemas são descritos por essas equações, que retratam o comportamento dinâmico do sistema (ARAÚJO 2018, SANTOS et al. 2018) discutem os modelos utilizados para esses sistemas indicam sua importância. Esses modelos são usados para sistemas que possuem n equações diferenciais, uma para cada movimento livre do sistema (DANTAS et al. 2020).




Figura 2.1: Sistema Massa-Mola-Amortecedor

Fonte: (DANTAS 2019)

O sistema mostrado na Figura 2.1 pode ser modelado usando equações diferenciais, conforme mostrado na Equação 2.1 e 2.2, segundo as leis clássicas da mecânica de Newton.

$$m_1 \ddot{x}_1(t) + d(2\dot{x}_1(t) - \dot{x}_2(t)) + k(2x_1(t) - x_2(t)) = 0 \quad (2.1)$$

$$m_2 \ddot{x}_2(t) + d(\dot{x}_2(t) - \dot{x}_1(t)) + k(x_2(t) - x_1(t)) = u \quad (2.2)$$

Sendo u sendo a entrada do sistema, m_1 e m_2 sendo as massas dos blocos, k sendo o coeficiente de rigidez das molas, d sendo o coeficiente de amortecimento, x_1 e x_2 sendo os deslocamentos dos blocos e \dot{x}_1 , \dot{x}_2 , \ddot{x}_1 e \ddot{x}_2 sendo respectivamente suas derivadas primeira e segunda, que representam as velocidades dos blocos e suas acelerações.

Em forma matricial as equações (2.1) e (2.2) podem ser reescritas da seguinte maneira:

$$\begin{bmatrix} m_1 & 0 \\ 0 & m_2 \end{bmatrix} \begin{bmatrix} \ddot{x}_1 \\ \ddot{x}_2 \end{bmatrix} + \begin{bmatrix} 2d & -d \\ -d & d \end{bmatrix} \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} + \begin{bmatrix} 2k & -k \\ -k & k \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix} u \quad (2.3)$$

Enquanto de forma simplificada:

$$\mathbf{M}\ddot{\mathbf{x}} + \mathbf{C}\dot{\mathbf{x}} + \mathbf{K}\mathbf{x} = \mathbf{B}u \quad (2.4)$$

sendo:

$$\mathbf{M} = \begin{bmatrix} m_1 & 0 \\ 0 & m_2 \end{bmatrix}, \mathbf{C} = \begin{bmatrix} 2d & -d \\ -d & d \end{bmatrix}, \mathbf{K} = \begin{bmatrix} 2k & -k \\ -k & k \end{bmatrix} \text{ e } \mathbf{B} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

Onde $\mathbf{M} \in \mathfrak{R}^{n \times n}$, é uma matriz de massas, $\mathbf{D} \in \mathfrak{R}^{n \times n}$ é uma matriz de amortecimento, $\mathbf{K} \in \mathfrak{R}^{n \times n}$ é uma matriz de rigidez, $\mathbf{B} \in \mathfrak{R}^{n \times m}$ é uma matriz de controle, $\mathbf{x} \in \mathfrak{R}^n$ é o vetor de deslocamento e $\mathbf{u} \in \mathfrak{R}^m$ é um vetor de entradas.

2.1.1 Representação de Primeira Ordem

A Equação (2.4) representa o sistema de segunda ordem em sua forma original. Outra maneira de interpretar o sistema descrito em (2.4) é usar representações de primeira ordem, como espaço de estado $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}u$.

Definindo $\mathbf{x} = \tilde{\mathbf{x}}_1$ e $\dot{\mathbf{x}} = \tilde{\mathbf{x}}_2$, podemos escrever o sistema de segunda ordem da equação (2.4) como:

$$\dot{\tilde{\mathbf{x}}}_1 = \tilde{\mathbf{x}}_2 \quad (2.5)$$

$$\dot{\tilde{\mathbf{x}}}_2 = -\mathbf{M}^{-1}\mathbf{K}\tilde{\mathbf{x}}_1 - \mathbf{M}^{-1}\mathbf{C}\tilde{\mathbf{x}}_2 + \mathbf{M}^{-1}\mathbf{B}u \quad (2.6)$$

na forma de matrizes:

$$\dot{\tilde{\mathbf{x}}} = \begin{bmatrix} \dot{\tilde{\mathbf{x}}}_1 \\ \dot{\tilde{\mathbf{x}}}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{0} & \mathbf{I} \\ -\mathbf{M}^{-1}\mathbf{K} & -\mathbf{M}^{-1}\mathbf{C} \end{bmatrix} \begin{bmatrix} \tilde{\mathbf{x}}_1 \\ \tilde{\mathbf{x}}_2 \end{bmatrix} + \begin{bmatrix} \mathbf{0} \\ \mathbf{M}^{-1}\mathbf{B} \end{bmatrix} u. \quad (2.7)$$

ou de maneira abreviada:

$$\dot{\tilde{\mathbf{x}}} = \mathbf{A}\tilde{\mathbf{x}} + \mathbf{B}u$$

com:

$$\mathbf{A} = \begin{bmatrix} \mathbf{0} & \mathbf{I} \\ -\mathbf{M}^{-1}\mathbf{K} & -\mathbf{M}^{-1}\mathbf{C} \end{bmatrix} \text{ e } \mathbf{B} = \begin{bmatrix} \mathbf{0} \\ \mathbf{M}^{-1}\mathbf{B} \end{bmatrix} \quad (2.8)$$

Essa representação é chamada de representação de primeira ordem padrão, enquanto outras formas de representações do sistema de segunda ordem é generalizada pelos escritores como forma do sistema descritor (DATTA 2004). Na literatura de controle, como (OGATA 2009), esta representação é tratada como uma representação de um sistema de equações diferenciais no espaço de estados, amplamente reconhecida na engenharia.

A motivação para a obtenção de um modelo de primeira ordem está na equação com uma solução mais simples do que a equação de segunda ordem. No entanto, algumas dificuldades numéricas surgem ao lidar com o sistema expresso dessa forma.

A primeira facilidade é que o número de equações no sistema, obtido a partir da análise da fórmula (2.7), pode-se saber que para obter a matriz \mathbf{A} , a matriz \mathbf{M} deve ser possível obter a inversa, também se a matriz \mathbf{M} não for bem condicionada, a sua inversa, então a matriz \mathbf{A} não seja calculada com precisão. Outro fato importante é as propriedades disponíveis das matrizes de coeficientes \mathbf{M} , \mathbf{C} e \mathbf{K} , como simetria. O qual em problemas de grande escala são informações importantes para representação em segunda ordem na Equação (2.7).

2.1.2 O Método da Receptância

O problema é, encontrar um conjunto de ganhos de controlador Proporcional Integral Derivativo (PID) que satisfaça o conjunto de autovalores desejados. O problema para encontrar esses ganhos solucionado em (MOTTERSHEAD e RAM 2007), para o controle ativo de vibrações, chamado de Método da Receptância, baseado em medições, que utiliza as matrizes de massa, rigidez e amortecimento, obtidas pelo método dos elementos finitos. Por ser um método baseado unicamente em dados medidos de vibrações, não há necessidade de se determinar, ou conhecer, essas matrizes (Tehrani et al. 2010).

A Determinação da Matriz Rigidez (\mathbf{K}) e de massas (\mathbf{M}) são menos desafiadoras porque de acordo com (MOTTERSHEAD e RAM 2007), os elementos finitos dessas matrizes podem ser facilmente determinados, usando métodos variacionais. No entanto, essa praticidade Funciona com matriz de amortecimento (\mathbf{C}). Algumas bibliografias o espaço de estados, e os elementos da matriz de amortecimento são definidos como padrões físicos confiáveis. As vibrações levemente amortecidas, pode ser aceitável como medida de estudos de controle ativo do modelo de amortecimento (NUNES 2022).

2.1.3 A Matriz de Receptância

Considerando o controle de um sistema de segunda ordem por realimentação de estados definido por

$$\mathbf{M}\ddot{\mathbf{x}}(t) + \mathbf{C}\dot{\mathbf{x}}(t) + \mathbf{K}\mathbf{x}(t) = \mathbf{B}u(t) \quad (2.9)$$

$$u(t) = k_p e(t) + k_i \int_0^t e(\tau) d\tau + k_d \frac{de(t)}{dt} \quad (2.10)$$

em que \mathbf{M} , \mathbf{C} , \mathbf{K} , \mathbf{B} , \mathbf{d} , $\in \mathbb{R}^{n \times n}$; $k_p, k_i, k_d, \in \mathbb{R}^n$; $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{M} = \mathbf{M}^T$, $\mathbf{C} = \mathbf{C}^T$, $\mathbf{K} = \mathbf{K}^T$; $\mathbf{v}^T \mathbf{M} \mathbf{v} > 0$, $\mathbf{v}^T \mathbf{C} \mathbf{v} \geq 0$ e $\mathbf{v}^T \mathbf{K} \mathbf{v} \geq 0$ para qualquer $\mathbf{v} \neq \mathbf{0}$, $\mathbf{v} \in \mathbb{R}^n$.

Substituindo (2.10) em (2.9), assumindo $\mathbf{x}(t) = \mathbf{z}e^{st}$, sendo \mathbf{z} um vetor constante e s a variável de Laplace, solução do sistema, tem-se:

$$\begin{aligned} (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K} - \mathbf{B}(k_p + \frac{k_i}{s} + k_d s))\mathbf{d} &= \mathbf{0} \\ (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K} - \mathbf{B}q(s))\mathbf{d} &= \mathbf{0} \end{aligned} \quad (2.11)$$

onde $q(s) = (k_p + \frac{k_i}{s} + k_d s)$ perceber que as componentes de malha fechada de rigidez e amortecimento são modificadas pela matriz de posto-1, consequência da realimentação

de estados.

A Fórmula de *Sherman-Morrison*

A fórmula de *Sherman-Morrison* fornece a inversa de uma matriz com modificação de posto-1 em termos da inversa da matriz original, e como visto em VAN LOAN e GOLUB (1983) e GOLUB e VAN LOAN (2012) ela estabelece que, para uma dada matriz $\mathbf{A} \in \mathfrak{R}^{n \times n}$ quadrada e inversível e vetores colunas \mathbf{u} e $\mathbf{v} \in \mathfrak{R}^n$:

$$(\mathbf{A} + \mathbf{u}\mathbf{v}^T)^{-1} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{1 + \mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}} \quad (2.12)$$

Aplicando a fórmula de *Sherman-Morrison* em (2.11) com $\mathbf{A} = (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K})$, $\mathbf{u} = \mathbf{B}$ e $\mathbf{v} = (k_p + \frac{k_i}{s} + k_d s)$, temos:

$$\hat{\mathbf{H}}(s) = \mathbf{H}(s) - \frac{\mathbf{H}(s)(k_p + \frac{k_i}{s} + k_d s)d\mathbf{H}(s)\mathbf{B}}{1 + (k_p + \frac{k_i}{s} + k_d s)d\mathbf{H}(s)\mathbf{B}} \quad (2.13)$$

na qual $\hat{\mathbf{H}}(s) = (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K} + bd(k_p + \frac{k_i}{s} + k_d s))^{-1}$ é definida em (RAM et al. 2009) como matriz de receptância de malha fechada e $\mathbf{H}(s) = (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K})^{-1}$ como matriz de receptância de malha aberta, que, na prática, pode ser medida pela resposta em frequência $\mathbf{H}(j\omega)$.

A equação característica de (2.13) é definida como:

$$1 + (k_p + \frac{k_i}{s} + k_d s)d\mathbf{H}(s)\mathbf{B} = 0 \quad (2.14)$$

e em MOTTERSHEAD e RAM (2007) a equação (2.14) é resolvida sendo reescrita da seguinte forma:

$$(k_p + \frac{k_i}{s} + k_d s)d\mathbf{H}(s)\mathbf{B} = 1$$

2.1.4 Sistema com Atraso

Quando existe um atraso no tempo entre o estado medido e a ação de controle do atuador podemos representar a lei de ação de controle da seguinte maneira:

$$u(t - \tau) = k_p e(t - \tau) + k_i \int_0^t e(t - \tau) d\tau + k_d \frac{de(t - \tau)}{dt} \quad (2.15)$$

sendo k_p, k_i e $k_d \in \mathfrak{R}^n$ e são vetores de ganho do sistema, desta forma, um sistema de controle de segunda ordem, como o da Figura 2.1, descrito pelo sistema de equações (2.4), com matrizes de massa $\mathbf{M} \in \mathfrak{R}^{n \times n}$, amortecimento $\mathbf{C} \in \mathfrak{R}^n$ e elasticidade $\mathbf{K} \in \mathfrak{R}^n$ pode ser escrito como:

$$\mathbf{M}\ddot{\mathbf{x}}(t) + \mathbf{C}\dot{\mathbf{x}}(t) + \mathbf{K}\mathbf{x}(t) = \mathbf{B}u(t - \tau) \quad (2.16)$$

Aplicando-se os procedimentos da seção anterior, para obtenção da matriz de receptância do sistema de segunda ordem com atraso descrito pela equação (2.16), com $\mathbf{x}(t) = \mathbf{z}e^{st}$, sendo \mathbf{z} um vetor constante e s a variável de Laplace, solução do sistema, tem-se:

$$\begin{aligned} (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K} - Bd(k_p + \frac{k_i}{s} + k_d s)e^{-\tau s}) &= \mathbf{0} \\ (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K} + e^{-\tau s}q(s)Bd)^{-1} &= \mathbf{0} \end{aligned} \quad (2.17)$$

e aplicando-se a fórmula de *Sherman-Morrison* como em (2.11)

$$\hat{\mathbf{H}}(s) = \mathbf{H}(s) - \frac{\mathbf{H}(s)(k_p + \frac{k_i}{s} + k_d s)d\mathbf{H}(s)Be^{-\tau s}}{1 + (k_p + \frac{k_i}{s} + k_d s)d\mathbf{H}(s)Be^{-\tau s}} \quad (2.18)$$

sendo novamente, $\hat{\mathbf{H}}(s) = (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K} + bd(k_p + \frac{k_i}{s} + k_d s)e^{-\tau s})^{-1}$ é definida como matriz de receptância de malha fechada e $\mathbf{H}(s) = (\mathbf{M}s^2 + \mathbf{C}s + \mathbf{K})^{-1}$ como matriz de receptância de malha aberta. A presença do atraso na equação (2.18) não modifica a possibilidade da obtenção de $\mathbf{H}(s)$ por sua resposta em frequência, uma das motivações para o desenvolvimento deste trabalho.

A equação característica da matriz de receptância de (2.18) é dada por:

$$\begin{aligned} 1 - (k_p + \frac{k_i}{s} + k_d s)d\mathbf{H}(s)Be^{-\tau s} &= 0 \\ (k_p + \frac{k_i}{s} + k_d s)d\mathbf{H}(s)B &= e^{\tau s} \end{aligned} \quad (2.19)$$

2.2 Resposta em Frequência

Na literatura clássica de controle, como em OGATA (2009), o termo resposta A frequência é definida como a resposta de estado estacionário do sistema à entrada senoidal, o que significa que experimentalmente, o sistema é excitado com uma onda senoidal entrada e observe o comportamento da saída. Trabalho realizado em resposta A frequência é muitas vezes motivada pelo bom desempenho em lidar com a incerteza nos modelos das plantas para facilitar o uso de informações experimentais Desenhar metas e ações na presença de atrasos no transporte (FRANKLIN et al. 2013).

2.2.1 O Diagrama Polar, ou Diagrama de Nyquist

A representação gráfica escolhida para o desenvolvimento deste trabalho é Nyquist, também conhecido como diagrama polar. Gráfico polar de uma função de transferência senoidal $G(j\omega)$ é a magnitude de $G(j\omega)$ e o ângulo de fase de $G(j\omega)$ em coordenadas polares, onde ω varia de zero a infinito de acordo com literatura base do (Ogata 2009). Um exemplo de gráfico de Nyquist para um sistema típico de segunda ordem é mostrado na equação (2.20) é mostrada na Figura 2.2.

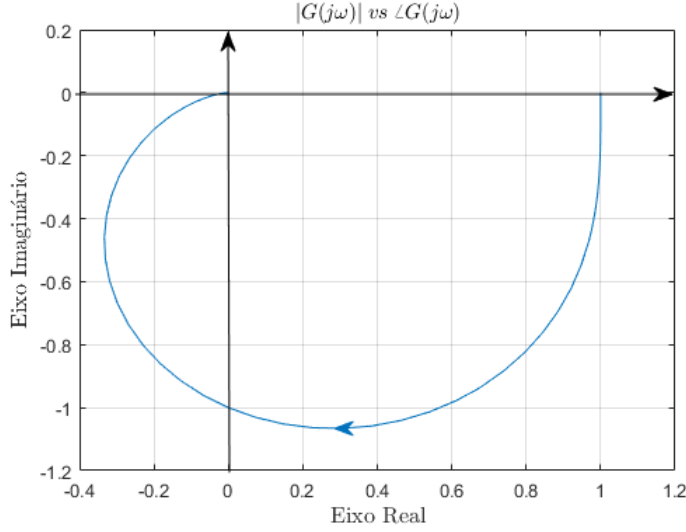


Figura 2.2: Exemplo de Diagrama de Nyquist para Sistema modelado por $G(s)$

Fonte: (DANTAS 2019)

$$G(s) = \frac{1}{s^2 + s + 1} \quad (2.20)$$

Outra maneira de interpretar um gráfico de Nyquist é pela parametrização por frequência ω de $G(j\omega)$, que mostra que esta representação tem alguns pontos não interessantes em comparação com outras representações gráficas, porque não há informações diretas sobre a frequência no gráfico em que na representação de *Bode* temos essa informação no diagrama. As curvas de Nyquist são caracterizadas pela simetria em relação ao eixo real e são muito comuns ao traçar essas curvas como mostra a Figura 2.3.

Métodos para obtenção das curvas são mostrado no livro de controle clássico como (OGATA 2009), (FRANKLIN et al. 2013) e (SKOGESTAD e POSTLETHWAITE 2007). Neste trabalho, as trajetórias de Nyquist são obtidas com o auxílio do MATLAB R2020a.

2.2.2 Critério de Estabilidade de Nyquist

O critério de estabilidade de Nyquist determina a estabilidade do sistema, baseado na resposta em frequência de um sistema em malha aberta. Em um sistema no circuito fechado descrito pela seguinte função de transferência:

$$G_{mf}(s) = \frac{C(s)}{R(s)} = \frac{G(s)}{1 + G(s)} \quad (2.21)$$

a equação característica é dada por

$$1 + G(s) = 0 \quad (2.22)$$

e para estabilidade, todas as raízes desta equação devem ter partes reais negativas, ou seja, O semiplano esquerdo (SPE) no plano S . Esse critério de estabilidade da equação de




Figura 2.3: Diagrama de Nyquist com a Parte Espelhada

Fonte: (DANTAS 2019)

Nyquist relaciona o número dessas raízes no semiplano direito (SPD) para com o número de voltas no ponto $(-1, 0)$ descrito na equação 2.23

$$Z = N + P \quad (2.23)$$

na qual Z representa o número de polos de malha fechada situados no SPD, N o número de envolvimentos do ponto $(-1, 0)$, no sentido horário, pelo traçado de Nyquist do ganho de malha de $G(j\omega)$ e P o número de polos de malha aberta no semi-plano direito de $G(s)$.

O número N pode ser negativo como também positivo, dependendo da orientação da volta, para cada contribuição em volta no ponto no sentido horário em N é positiva, e para cada volta no sentido anti-horário conta como uma contribuição negativa. Esse argumento é baseado no teorema do mapeamento complexo ou Teorema Cauchy, que cria uma relação a curvas em domínios funcionais com o domínio s . Segundo o (OGATA 2009) a análise de estabilidade do sistema pode ser resumido para três casos possíveis:

1. Não existir nenhum envolvimento do ponto $-1 + j0$. Implicando onde o sistema será estável se não houver polos de malha aberta no SPD do plano s , e instável caso contrário;
2. Existir um ou mais envolvimentos do ponto $-1 + j0$ no sentido anti-horário. Implicando que, para o sistema estável, nesse caso, o número de envolvimentos tem que ser igual ao número de polos de malha aberta no SPD;
3. Existir um ou mais envolvimentos do ponto $-1 + j0$ no sentido horário, implicando nesse caso em instabilidade.

Baseado no teorema do mapeamento, FRANKLIN et al. (2013) resume em quatro passos básicos o processo de determinação de estabilidade de um sistema pelo critério de estabilidade de Nyquist:

1. Obter o diagrama de Nyquist do ganho de malha do sistema, geralmente representado por (2.21);
2. Avaliar o número de envoltimentos do ponto $-1 + j0$ no sentido horário (N), se o envolvimento for no sentido anti-horário o número é negativo;
3. Determinar o número de polos instáveis em malha aberta (P);
4. Calcular o número de raízes instáveis em malha fechada: $Z = N + P$

Vantagens de usar a análise de estabilidade pelo critério de estabilidade de Nyquist é que o número de polos (Z) não precisa necessariamente ser encontrado, então não há necessidade de expressar matematicamente os atrasos por meio de funções de transferência de ordem finita, eliminando o uso de aproximações, assim melhorando sua fidelidade nos resultados.

2.3 Controlador Proporcional Integrativo Derivativo

O Controlador Proporcional Integrativo Derivativo (PID) une as ações proporcional, integral e derivativa num só controlador, atuando tanto no regime transitório quanto no regime permanente. São utilizados em sistema de controle industriais, onde ele introduz em polo em 0 e dois zeros, que dependem dos parâmetros de controlador, e tendemos a zeros serem reais e iguais para melhorar a estabilidade (GONTIJO et al. 2022).

Existem muitas maneiras de representar um PID por função de transferência, uma delas é esta:

$$G_c(s) = \frac{U(s)}{E(s)} = K_p + \frac{K_i}{s} + K_d s = \frac{s^2 K_d + s K_p + K_i}{s} = K_c \frac{(s + z_1)(s + z_2)}{s} \quad (2.24)$$

Na Figura 2.4, mostra o Controlador PID, como representação de diagramas de blocos, percebe também que essa representação já está com melhorias como filtro derivativo, como objetivo de tratar variações bruscas do sinal de referência.




Figura 2.4: Diagrama de blocos do PID

Fonte: Autor

Na literatura de controle como (OGATA 2009), o método Lugar Geométrico das Raízes (LGR), *Zigler-Nichols* são algumas técnicas de projetos de controladores PID.

Os passos comum para projeto de controladores PID é:

1. Traduzir as especificações de desempenho como uma localização desejada de polos dominantes de malha fechada
2. Verificar se o objetivo não pode ser atingido com um controlador mais simples
3. Se o PID é necessário, localizar o polo na origem e os zeros de modo que a condição de ângulo seja satisfeita
4. Calcular o ganho total requerido, aplicando a condição de módulo
5. Simular o sistema com o controlador e observar o comportamento da resposta. Caso não seja satisfatório, tentar um ajuste fino dos parâmetros do controlador (K_c, z_1 e z_2)

Porém, neste trabalho não utilizaremos soluções lineares, sim, soluções heurísticas, com o uso de Algoritmo Genético e Enxames de Partículas para encontrar os valores dos ganhos que satisfaçam as nossas restrições de estabilidade Nyquist.

2.4 Índices de desempenho

Os índices de desempenhos são medidas quantitativa do desempenho de um sistema, esses índices consideram fatores, como erro do sistema, o tempo. E para cada sistema é preciso identificar qual o maior fator relevante para o sistema a qual queremos atingir o ótimo. Dizemos que o sistema de é **ótimo** quando o índice de desempenho selecionado é minimizado, em nosso caso o algoritmo genético irá minimizá-lo.

Alguns índices de desempenhos são:

- Integral do erro ao quadrado (*ISE*)

$$ISE = \int_0^T e^2(t) dt \quad (2.25)$$

Esse índice tem empenho entre resposta subamortecidas e super-amortecida, consiste na medida do valor é dado pela integral do quadrado do erro atuante para uma malha de controle. o *ISE* tem uma maior sensibilidade aos erros grandes, porque, o desvio em relação ao sinal de referência é grande, contribui com uma maior parcela no resultado da integral, do que erro quadrático cuja magnitude seja menor. Porém, esse índice tendem que erros pequenos persistam na resposta do sistema por um tempo maior, por exemplo, oscilações longas e de pequenas amplitudes no sinal.

- Integral do erro absoluto (*IAE*)

$$IAE = \int_0^T |e(t)| dt \quad (2.26)$$

O índice IAE gera respostas mais lentas que *ISE* segundo, (OGATA 2009). A formulação é definida como integral do módulo do erro atuante, logo pode se notar que é atuação contrária ao *ISE*, o *IAE* não, adiciona qualquer tipo de peso ao erro citado, ao minimizar o sistema considerando *IAE* podemos afirmar que a resposta

será mais lenta, contudo espera-se que o sistema de controle apresente menos oscilações na saída.

- Integral do erro absoluto vezes o tempo (*ITAE*)

$$ITAE = \int_0^T t|e(t)|dt \quad (2.27)$$

O efeito desse índice tem como principal fator é reduzir a contribuição do erro nos primeiros segundos e olhando para erro presente na resposta do regime do transitório. o *ITAE* é um índice mais seletivo no qual o seu valor mínimo é facilmente identificável em função do amortecimento ζ do sistema. Geralmente os sistemas que utiliza a sintonia do controlador pela minimização do *ITAE* tendem a atingir o regime permanente de forma mais rápida.

- Integral do erro ao quadrado vezes o tempo (*ITSE*)

$$ITSE = \int_0^T te^2 dt \quad (2.28)$$

O *ITSE*, como também *ITAE* tem foca nas penalizações de oscilações persistentes, com objetivo de reduzir o tempo de acomodação.

2.5 Robustez de Estabilidade

Alguns sinais, como distúrbio $d(t)$ e ruído/erro de medida $n(t)$ que estão no sistema de controle em malha fechada, além de serem incertos, causam efeitos indesejáveis.

Quando um modelo do sistema em malha fechada com incertezas multiplicativas, com perturbações $\delta(j\omega) = 0$ ou seja abrir a malha e determinar a função de transferência, de modo que obtemos um novo sistema em malha fechada que $\delta(j\omega)$ é a função de transferência de ramo direto, $H(j\omega)$ é a função de transferência de realimentação e a referência nula. Dessa forma, tem uma estabilidade em MF para qualquer $\delta(j\omega)$, assim podemos aplicar critério de *Nyquist*, com função de transferência de malha aberta igual a $\delta(j\omega)H(j\omega)$:

1. Por hipótese dizemos que $W(j\omega), \delta(j\omega)$ é estável sendo que as que $T(j\omega)$ afirmando que sempre o sistema é nominal, com isso temos que $P = 0$ para qualquer $\delta(j\omega)$.
2. Logo para qualquer $\delta(j\omega)$ o sistema em MF deve ser estável, logo $Z = 0$.

Devemos ter $N = 0$, o que significa que o gráfico de *Nyquist* de $1 + \delta(j\omega)H(j\omega) \neq 0$ para qualquer $\delta(j\omega)$, pela definição do critério de estabilidade de *Nyquist* isso é possível somente quando ocorre a seguinte situação em que $|1 + \delta(j\omega)H(j\omega)| > 0$. Quando falamos de números complexos, no pior caso, temos quando $1 - |\delta(j\omega)H(j\omega)| > 0$ e como $|\delta(j\omega)| = 1$ logo temos que $|H(j\omega)| = |W(j\omega)T(j\omega)| < 1$ para qualquer frequência, ou seja, $|T(j\omega)| < 1/|W(j\omega)|$ o qual é condição de robustez de estabilidade. Também essa condição de estabilidade é satisfeita quando $\|WT\|_\infty < 1$ de acordo com (Hespanha 2018).

2.6 Sistemas Multivariéis

Na indústria, a maioria dos sistemas são multivariáveis ou Multi-input, Multi-output (MIMO), isso significa que o sistema tem mais de uma entrada e mais de uma saída, e modificar uma variável manipulada influencia mais de uma variável. Essa consequência é chamada de acoplamento entre variáveis.

Na Figura 2.5 temos um sistema multivariável com duas entradas e duas saídas. Para esse caso, quando temos um sistema $n \times n$, temos $n!$ possíveis acoplamentos diferentes.




Figura 2.5: Sistema multivariável

Fonte: Autor

para o sistema da Figura 2.5, temos dois emparelhamentos de controle possível, são eles:

- U1 com Y1, U2 com Y2
- U1 com Y2, U2 com Y1

A dinâmica do processo, é necessário ter quatro funções de transferência, duas para variáveis de controle (VC) e duas para variáveis manipuladas (VM) sendo elas:

$$\frac{Y_1(s)}{U_1(s)} = G_{P11}(s), \frac{Y_1(s)}{U_2(s)} = G_{P12}(s) \quad (2.29)$$

$$\frac{Y_2(s)}{U_1(s)} = G_{P21}(s), \frac{Y_2(s)}{U_2(s)} = G_{P22}(s) \quad (2.30)$$

assim as relações de entrada e saída pode ser descrita conforme abaixo:

$$Y_1(s) = G_{P11}(s)U_1(s) + G_{P12}(s)U_2(s) \quad (2.31)$$

$$Y_2(s) = G_{P21}(s)U_1(s) + G_{P22}(s)U_2(s) \quad (2.32)$$

ou na forma matricial

$$\begin{bmatrix} Y_1(s) \\ Y_2(s) \end{bmatrix} = \begin{bmatrix} G_{P11}(s) & G_{P12}(s) \\ G_{P21}(s) & G_{P22}(s) \end{bmatrix} \begin{bmatrix} U_1(s) \\ U_2(s) \end{bmatrix} \quad (2.33)$$

Para projeto de sistemas de controle com multivariáveis os seguintes passos são comuns, segundo (OGATA 2009):

1. Selecionar as variáveis controladas e manipuladas
2. Selecionar o emparelhamento das variáveis controladas e manipuladas
3. Especificar os tipos de controladores, no caso um controlador para cada variável controlada.

Capítulo 3

Formulação do Problema

O sistema matricial de equações diferenciais de 2º grau mostrado em (3.1), aparece frequentemente em uma gama variada de aplicações em análises estruturais e de vibrações como em BALAS (1982) e VANDERVELDE (1986), onde $\mathbf{M} \in \Re^{n \times n}$, é uma matriz de massas, geralmente definida positiva; $\mathbf{C} \in \Re^{n \times n}$ é uma matriz de amortecimento, geralmente, pelo menos, semi definida positiva; $\mathbf{K} \in \Re^{n \times n}$ é uma matriz de rigidez, também sendo semi definida positiva na maior parte das vezes; $\mathbf{B} \in \Re^{n \times m}$ é uma matriz de controle (também vista como matriz de influência ou de atuadores) de posto completo; $\mathbf{x} \in \Re^n$ é o vetor de estado, que para sistemas mecânicos como os da Figura 2.1, representa o deslocamento e $\mathbf{u} \in \Re^m$ é um vetor de entradas.

$$\mathbf{M}\ddot{\mathbf{x}}(t) + \mathbf{C}\dot{\mathbf{x}}(t) + \mathbf{K}\mathbf{x}(t) = \mathbf{B}\mathbf{u}(t - \tau) \quad (3.1)$$

A saída do sistema definida como:

$$\mathbf{y}(t) = \mathbf{e}(t - \tau)\mathbf{d}\mathbf{x}(t) \quad (3.2)$$

Considere-se o monovariável, ou seja, $d \in \Re^{1 \times n}$.

e erro do sistema é definido como:

$$e(t) = r(t) - y(t) \quad (3.3)$$

Assume-se a lei de controle por realimentação de estados como:

$$u(t - \tau) = k_p e(t - \tau) + k_i \int_0^t e(t - \tau) d\tau + k_d \frac{de(t - \tau)}{dt} \quad (3.4)$$

em que k_p, k_i e $k_d \in \Re$ são os vetores de ganho do controlador. Substituindo a equação (3.4) na equação (3.1) e realizando os procedimentos apresentados na seção 2.1.3.

Considerando:

$$V(s) = q(s)R(s), \text{ com } q(s) = (k_p + \frac{k_i}{s} + k_d s)$$

$$U(s) = -(k_p + \frac{k_i}{s} + k_d s)e^{-\tau s}dX(s) + V(s) \quad (3.5)$$

$$(Ms + Cs + K + e^{-\tau s} q(s) dB)X(s) = V(s) \quad (3.6)$$

$$x(s) = (Ms + Cs + K + e^{-\tau s} q(s) dB)^{-1} V(s) \quad (3.7)$$

aplicando a fórmula de *Sherman-Morrison*, chega-se a matriz de receptância dada por:

$$\hat{\mathbf{H}}(s) = \mathbf{H}(s) - \frac{\mathbf{H}(s)(k_p + \frac{k_i}{s} + k_d s) d\mathbf{H}(s) B e^{-\tau s}}{1 + (k_p + \frac{k_i}{s} + k_d s) d\mathbf{H}(s) B e^{-\tau s}} \quad (3.8)$$

Trabalhos relacionados ao controle em malha fechada aplicados a sistemas de segunda ordem têm ganhado cada vez mais notoriedade devido a sua relevância prática.

3.1 Parâmetro de Projeto e Formulação Matemática

Margens de ganho e de fase são usualmente utilizadas como parâmetros de projeto de controladores por resposta em frequência. As relações entre a resposta temporal e essas margens fornecem boas referências, ainda que dadas de maneira indireta, para o controle de sistemas via resposta em frequência. Em algumas referências essas margens são chamadas de margens de estabilidade, muito embora para casos com sistemas com mais de um grau de liberdade essas não sejam medidas de estabilidade muito precisas.

Circunferência M_s

Dadas as discussões anteriores sobre estabilidade com a definição do critério de estabilidade de Nyquist, uma conclusão para sistemas estáveis em malha aberta, ou seja, sem nenhum polo de malha aberta no SPD ($P = 0$), é que não se deve haver nenhum envolvimento do ponto $(-1, 0)$ pelo diagrama de Nyquist do sistema. Assim, surge a ideia de se definir como parâmetro de projeto uma medida que garanta estabilidade visando atender a este critério. SKOGESTAD e POSTLETHWAITE (2007) em uma discussão acerca de critérios de picos máximos trazem a ideia da relação entre o chamado pico máximo da função de sensibilidade e a menor distância entre o ponto $(-1, 0)$ e o diagrama de Nyquist do ganho de malha do sistema. Baseado nesse conceito, define-se uma circunferência de raio M_s^{-1} centrada no ponto $-1 + j0$ delimitando a região onde o traçado de Nyquist é permitido, assim, garantindo uma distância segura do ponto $(-1, 0)$, ilustrando a ideia de sistema robusto.

Definição do problema de otimização

A figura 3.1 mostra o diagrama de Nyquist de um sistema genérico (traçado em azul) e uma circunferência (em vermelho) representando a circunferência M_s . À medida que o ganho do sistema aumenta o diagrama de Nyquist invade a área da circunferência e se aproxima do ponto $-1 + j0$ chegando próximo da fronteira da instabilidade. Com essa ideia, define-se como parâmetro de projeto que o sistema tenha uma distância mínima




Figura 3.1: Diagrama de Nyquist Exemplo de Circunferência. M_s
 Fonte: (DANTAS 2019)

do ponto $(-1,0)$ definida pelo raio dessa circunferência. A solução apresentada neste trabalho visa garantir uma estabilidade robusta, a fim de garantir que mesmo sujeito a alterações de parâmetros o sistema seja estável. Para isso deve-se manter o ponto $(-1,0)$ a uma distância segura de $L(j\omega)$, o que pode ser interpretado como o traçado de $L(j\omega)$ fora de uma circunferência centrada em $(-1,0)$ cujo raio seria a distância mínima desejada com o cuidado de não apresentar soluções nas quais as curvas de $L(j\omega)$ estejam muito afastadas do círculo, o que levaria a respostas muito lenta. Dessa forma, busca-se fazer com que a curva de $L(j\omega)$ tangencie o círculo M_s estabelecido e então o seguinte problema de otimização pode ser formulado:

$$\min_{k_p, k_i, k_d} h(k_p, k_i, k_d) = \left(\min_{\omega_i} |L(j\omega) + 1| - M_s^{-1} \right)^2 \quad (3.9)$$

$$\begin{aligned} s.a. \quad L(j\omega_i) &= \left(k_p + \frac{k_i}{j\omega_i} + k_d j\omega_i \right) d\mathbf{H}(j\omega_i) B e^{-j\omega_i \tau} \\ \text{Re}\{L(j\omega_i)\} &\geq -1 + M_s^{-1} \quad \forall \quad \omega_i / \text{Im}\{L(j\omega_i)\} = 0 \end{aligned} \quad (3.10)$$

sendo que o subscrito i indica o i -ésimo valor de frequência com ω variando de zero a um valor elevado o suficiente para que $|L(j\omega)| \simeq 0$. A equação (3.9) estabelece o problema de minimização da função genérica $h(k_p, k_i, k_d)$, que por ser uma função quadrática terá seu valor mínimo para $(\min_{\omega_i} |L(j\omega) + 1| = M_s^{-1})$, e como $(\min_{\omega_i} |L(j\omega) + 1|)$ é a menor distância entre $L(j\omega)$ e o ponto $(-1,0)$, a igualdade significa que o valor mínimo para o problema dado pela equação (3.9) se dará num ponto tangente a circunferência de raio M_s^{-1} .

3.2 Otimização de Desempenho

O problema de otimização definido matematicamente pela equação (3.9) estabelece a busca por um conjunto de vetores de ganho de controlador que garantam que a curva de Nyquist do sistema de segunda ordem não adentre a região delimitada pela circunferência centrada no ponto $(-1, 0)$, de raio M_s^{-1} . A restrição dada pela equação (3.10) garante que soluções como a de um conjunto de solução aleatória mostrado na figura 3.2 não sejam obtidas pela busca, pois como ilustrado, a curva de Nyquist da figura 3.2 enlaça o ponto $(-1, 0)$, ilustrando instabilidade (MARTINS et al. 2020).

O problema de otimização dado pela equação (3.9) não garante, todavia que o desempenho da resposta seja considerada diretamente, apesar da ideia de robustez, não se garante respostas rápidas tão quanto desejadas somente com a definição da região “proibida” para o traçado da curva de Nyquist de $L(j\omega)$. Em alguns trabalhos na literatura o desempenho do sistema é abordado utilizando-se técnicas de ajuste de curva, sintonia de ganhos do controlador, integral do erro e itens relacionados a resposta temporal (EUZÉBIO e BARROS 2015, EUZÉBIO e BARROS 2013).




Figura 3.2: Diagrama de Nyquist de um Sistema Genérico para Exemplo de um Caso de Instabilidade.

Fonte: (DANTAS 2019)

Restrição adicional

Em SKOGESTAD e POSTLETHWAITE (2007) é visto que as margens de ganho e de fase do sistema têm uma relação direta com a circunferência M_s . A definição dessa circunferência como parâmetro de projeto por resposta em frequência garante um mínimo de margem de ganho e margem de fase, tornando redundante essas especificações, uma vez definido o valor de M_s desejado. Segundo (SKOGESTAD e POSTLETHWAITE

2007) define matematicamente que:

$$GM \geq \frac{M_s}{M_s - 1}; \quad PM \geq 2\arcsen\left(\frac{1}{2M_s}\right) \geq \frac{1}{M_s}[\text{rad}] \quad (3.11)$$

sendo GM a margem de ganho ("*gain margin*") e PM a margem de fase ("*phase margin*"). Da equação (3.11) pode-se concluir que, definido um valor M_s garante-se um mínimo valor de GM e PM .

Na literatura clássica de controle como em OGATA (2009) e FRANKLIN et al. (2013) a margem de ganho é definida como um fator pelo qual o ganho do sistema pode ser aumentado antes de atingir a instabilidade, e a influência na resposta temporal do sistema é refletida em sua velocidade, respostas mais rápidas são alcançadas para sistemas com menores margens de ganho. Uma vez que se define com M_s um indicativo de robustez, mesmo um mínimo de margem de ganho ainda seria confortável. Assim, a menor margem de ganho (e consequentemente melhor desempenho em velocidade de resposta) se daria para o caso limite sendo:

$$GM = \frac{M_s}{M_s - 1}$$

o que significa graficamente que o diagrama de Nyquist do sistema tangencia a circunferência de raio M_s no ponto sobre o eixo real (uma vez que a margem de ganho é dada como o ganho do sistema quando a fase é igual a -180°), concluindo-se que dentre as soluções para o problema de otimização apresentado pela equação (3.9) as que apresentariam melhor desempenho seriam aquelas que tangenciam a circunferência M_s no ponto da circunferência sobre o eixo real. para isso ajustaremos novamente os critérios de otimização da seguinte forma:

$$\begin{aligned} \min_{k_p, k_i, k_d} \quad & h(k_p, k_i, k_d) = \left(\min_{\omega_i} |L(j\omega) + 1| - M_s^{-1} \right)^2 \\ \text{s.a.} \quad & L(j\omega_i) = -(k_p + \frac{k_i}{j\omega_i} + k_d j\omega_i) d\mathbf{H}(j\omega_i) b e^{-j\omega_i \tau} \\ & \text{Re}\{L(j\omega_i)\} \geq -1 + M_s^{-1} \quad \forall \omega_i / \text{Im}\{L(j\omega_i)\} = 0 \\ \min_{\omega_i} \quad & \text{Re}\{L(j\omega_i)\} = -1 + M_s^{-1} \quad \forall \omega_i / \text{Im}\{L(j\omega_i)\} = 0 \end{aligned} \quad (3.12)$$

A restrição da equação (3.12) garante que o menor valor dentre os valores reais da curva de Nyquist de $L(j\omega)$ cuja parte imaginária é igual a zero seja igual ao raio da circunferência $M_s - 1$, sendo a distância entre a origem e o ponto da circunferência sobre o eixo imaginário, garantindo assim, que o diagrama de Nyquist tangencie a circunferência neste ponto (DANTAS 2019).

3.3 Abordagem para sistemas instáveis

Neste trabalho também aplicaremos os métodos testado para sistema de controle estáveis para sistemas instáveis, porém isso traz algumas complicações nas aplicações das

funções de restrições mostrado na equação 3.12.

Pelo critério de Nyquist, todas as raízes precisam de reais e negativas, mas quando temos um sistema instável significa que temos raízes no SPD, e para tornar esse sistema estável, precisamos forçar que o número de voltas no ponto $(-1,0)$ seja igual ao número de raízes semi plano direito, assim tornando o sistema estável. Para isso nosso algoritmo escolhe de forma heurística os ganhos do controlador PID, para atender essa condição de voltas, igual o número de polos de malha aberta no SPD, logo no algoritmo precisar ficar monitorando o número de voltas e quantidade de polos, para atender essa condição.

Esta problemática, de impor o número de voltas adequadas do diagrama de Nyquist, é complexo e que neste trabalho visamos estudar para tentar resolver. Inicialmente precisamos implementar uma técnica que consiga contar o número de voltas no ponto $(-1,0)$.

Capítulo 4

Implementação do Método Proposto

Este capítulo tem como objetivo apresentar o método desenvolvido para alcançar os resultados apresentados no Capítulo 5. A busca por uma solução para o problema de otimização descrito no Capítulo 3 é feita usando um algoritmo genético, um algoritmo estocástico baseado em população que procura soluções aleatoriamente por meio de mutação e cruzamento entre os membros da população. Este algoritmo pode ser utilizado para solucionar problemas de otimização, tanto suaves como não suaves, com restrições lineares ou não lineares (MathWorks 2019, Goldberg e Holland 1988).

4.1 Solução do Problema de Otimização

Uma das alternativas para solucionar problemas de otimização, como o descrito na equação (3.9), é o uso do algoritmo genético (GA), um método para solução de problemas de otimização com ou sem restrições baseado no processo de seleção natural que imita a evolução biológica. O GA é um pioneiro na solução de problemas do tipo abordado neste trabalho (MathWorks 2019). O algoritmo funciona repetitivamente alterando a população de soluções individuais. A cada etapa, o algoritmo genético escolhe aleatoriamente indivíduos da população atual e os utiliza como pais para gerar filhos para a geração seguinte. Ao longo de sucessivas gerações, a população evolui até chegar a uma solução ótima. O que é perfeitamente adequado ao objetivo de procura para o problema descrito pela equação (3.12).

O algoritmo genético pode ser utilizado para resolver problemas que não são adequados aos algoritmos de otimização padrão, incluindo aqueles em que a função objetivo é descontínua, não diferenciável, estocástica ou altamente não linear. A função objetivo neste caso é abordada pela curva de Nyquist do sistema para os valores desejados de $\mathbf{k_p}$, $\mathbf{k_i}$ e $\mathbf{k_d}$.

Algoritmo genético desenvolvido

No trabalho apresentado, optou-se por desenvolver o algoritmo genético devido à facilidade de otimização dos hiperparâmetros e obtenção de melhores resultados com variações dos métodos principais do GA, tais como seleção, cruzamento e mutação. (SOUZA 2020)

Os passos do algoritmo genético implementado foram:

1. Inicialização: Uma população inicial de soluções é gerada aleatoriamente de **kp**, **ki** e **kd**.
2. Seleção: Os indivíduos são ordenados de forma que os ganhos do controlador que tiveram melhor resultados estão no início da população e esses são selecionados para reprodução, esse tipo de seleção é denominado de elitista.
3. Cruzamento: Os ganhos do PID selecionados são usadas como pais para produzir novos indivíduos (filhos).
4. Mutação: Alguns dos indivíduos produzidos são submetidos a pequenas alterações aleatórias (mutações).
5. Avaliação: A nova geração de soluções é avaliada em termos de sua aptidão com função de otimização, em nosso trabalho utilizamos robustez do sistema, integral do erro absoluto e concorrência entre eles.
6. Variabilidade Genética: Implementamos esse calculo a fim de verificar a variação dos resultados da função de otimizando, reduzindo o tempo de otimização desnecessários quando não tem ganhos significativos a cada interação.
7. Substituição: A nova geração de soluções é substituída pela antiga, formando a nova população.
8. Repetição: O processo é repetido sucessivas vezes até que se atinja uma solução ótima ou se alcance um critério de parada.
9. Resultado: A melhor solução encontrada é retornada como resultado do algoritmo genético.

Essas variações no comportamento do passo de seleção, como seleção por elitismo, seleção randômica, seleção por roleta, bem como variações no método de cruzamento, como cruzamento em dois pontos ou uniforme, e a mutação gaussiana ou uniforme, podem trazer grandes ganhos na otimização do GA, dependendo da formulação do problema e de como ele se comporta no espaço de amostra (SOUZA 2020).

O objetivo é seguir as etapas do Algoritmo 1 para encontrar os valores ideais de K_p , K_i e K_d que resolvem o problema de otimização específico apresentado na seção 5. Para utilizar essa função, é necessário fornecer matrizes que descreva o sistema de segunda ordem (**M**, **C**, **K**, **B**, **d**), o atraso do sistema τ , as frequências em que o sistema atua ω , a circunferência M_s e o nome do arquivo de simulação do sistema **Simulink**.

O programa também utiliza funções personalizadas, como uma função de restrição para descrever as limitações impostas pelas equações (3.10), uma função de robustez que avalia a capacidade do sistema em malha fechada de lidar com variações, conforme definida pela equação (3.9), uma função de IAE que calcula a integral do erro absoluto no sistema em malha fechada, conforme definido pela equação (2.27), e uma função *Fitness* que calcula o valor a ser minimizado pelo algoritmo genético. Dependendo do valor da variável *alfa*, a robustez do sistema ou o IAE em malha fechada podem ser otimizados, bem como a combinação desses parâmetros no sistema.

Algoritmo 1: Função de Busca

Entrada: M ; C ; K ; B ; d ; τ ; ω ; M_s e **simulink**
Saída: gain = [K_p K_i K_d];

```

1 populacao = random(n);
2 objetivo = "execute";
3 execucao = 0;
4 variabilidade = 1;
5 evolucao = 0;
6 alfa = random(0,1);
7 n = 100;
8 repita
9   para geracao=1 até geracao=n faça
10    avalicao = []
11    se execucao > 0 então
12     | populacao(2:n,:) = random(n-1);
13    fim
14    para i = 1 até populacao=n faça
15     L ← LFunction(M, C, K, B, d,  $\tau$ ,  $\omega$ , populacao(i, 1:3));
16     robustez ← RobustezFunction(L(s),  $M_s$ );
17     restrictions ← RestrictionsFunction(L(s), 0);
18     IAE ← IaeFunction(populacao, simulink);
19     ff ← FitnessFunction(IAE, robustez, alfa);
20     avaliacao(i,1:end) = [ff, restrictions];
21     i = i + 1;
22    fim
23    populacao = [populacao avaliacao];
24    populacao ← AssortmentFunction(populacao);
25    populacao ← CrossOverFunction(populacao(1:n,1:end-2));
26    L ← LFunction(M, C, K, B, d,  $\tau$ ,  $\omega$ , populacao(1, 1:3));
27    robustez ← RobustezFunction(L(s),  $M_s$ );
28    restrictions ← RestrictionsFunction(L(s), 0);
29    IAE ← IaeFunction(populacao, simulink);
30    ff ← FitnessFunction(IAE, robustez, alfa);
31    se (ff < 0.4 && restrictions < 0.9) || (execucao >
32      2 && Restrictions < 0.9) então
33     | objetivo = "fim";
34     | melhorIndividuo = populacao(1,:);
35     | interromper;
36    fim
37    VariabilidadeFunction(variabilidade, evolucao, ff);
38    geracao = geracao + 1;
39  fim
40 até (objetivo  $\neq$  "fim");

```

População inicial

A primeira etapa na configuração de um algoritmo genético consiste em criar a população inicial. Esse termo, assim como todos os outros relacionados ao algoritmo, é inspirado na analogia com a teoria da evolução biológica. No contexto de otimização, ele se refere ao conjunto inicial de soluções possíveis para o problema específico em questão.

Neste trabalho, optou-se pelo desenvolvimento de um conjunto aleatório de indivíduos para a população. Inicialmente, criamos uma população com cem indivíduos, onde o primeiro *locus* corresponde a K_p , seguido por K_i , e K_d . Ao tentar resolver o problema descrito pela equação (3.9).

4.2 Problemas na implementação

ESCREVER ALGO AQUI

Procedimento baseado em "*detuning*"

A restrição estabelecida pela equação (3.10) tem como objetivo garantir a estabilidade do sistema diante da resposta obtida pelo algoritmo genético. Em alguns casos, como em sistemas sem amortecimento em que os polos de malha aberta estão localizados no eixo imaginário, pode ser desafiador trabalhar com a resposta em frequência devido às discontinuidades que esses pontos geram na relação entre os planos s e $j\omega$). Essa dificuldade pode se refletir na solução retornada pela busca do algoritmo genético, manifestando-se como um mínimo local ou até mesmo como uma solução inexistente para o problema definido com as restrições apresentadas.

Com base na ideia apresentada em Santos SANTOS et al. (2018) para sistemas com atraso variável e motivado por essa dificuldade, é gerada uma população inicial em que todos os indivíduos possuem soluções estáveis.

Para gerar a população inicial, segue-se o seguinte procedimento. Inicialmente, define-se um conjunto de indivíduos da população inicial $[K_p \ K_i \ K_d]$, sem restrições quanto à sua definição. Uma sugestão é utilizar o vetor calculado pelo método proposto em MOTTERSHEAD e RAM (2007) para sistemas sem atraso, ou simplesmente um vetor com ganho unitário. Em seguida, verifica-se a estabilidade do sistema com o ganho de malha $[K_p \ K_i \ K_d]$ estabelecido no passo anterior. Caso o sistema seja instável, multiplica-se o vetor $[K_p \ K_i \ K_d]$ por um valor $0 \leq \alpha \leq 1$ e novamente verifica-se a estabilidade com o novo ganho $\alpha[K_p \ K_i \ K_d]$. Repete-se esse processo, reduzindo gradativamente o valor de α , até atingir a estabilidade. A partir daí, constrói-se o conjunto de indivíduos da população inicial conforme o algoritmo 2, essa solução para esse problema não é tratado neste trabalho.

Algoritmo 2: População Inicial

Entrada: $L(s) = (k_p + \frac{k_i}{s} + k_d s) dH(s) B e^{-\tau s}$;
Saída: populacao

```

1 populacao = [];
2 para i = 1 até i = 100 faça
3      $\alpha = 1 - \frac{(i-1)}{100}$ ;
4     se LFunction( $M, C, K, B, d, \tau, \omega$ , populacao(i, 1:3)) é estável então
5         | populacao=[populacao  $\alpha[Kp \ Ki \ Kd]$ ];
6     fim
7     i = i + 1;
8 fim

```

Erros numéricos causam Nyquist infinito

Além disso, devido à natureza do controlador integrativo, para frequências altas, o cálculo do diagrama de *Nyquist*, devido natureza aleatória da população, pode ocorrer problema numéricos de valores infinitos para o ganho integrativo do PID. Com isso, a depender dos valores de frequência ω , o algoritmo pode ter duas visões diferentes do gráfico de *Nyquist*, e como função de restrição é modelada com base nesse diagrama, o algoritmo pode ter interpretação errada.



Por exemplo, quando utilizamos o sistema do exemplo 5.1.3, do capítulo 5 o método resultou nos seguintes ganhos do controlador PID [7.9574 14.8018 3.5920] respectivamente Kp, Ki, Kd na figura 4.1, o qual as frequências ω tem uma variação de $[10^{-1} \ 10^3]$ podemos observar que o diagrama não envolve o ponto de instabilidade $-1 - j\omega$, e com base na definição de estabilidade de *Nyquist* o sistema é estável em malha aberta. Mas, para os mesmo valores dos ganhos, com a variação do ω de $[10^{-6} \ 10^3]$, quando observamos a figura 4.2, o gráfico envolve o ponto de instabilidade, assim quando ocorre um diagrama que tem casos infinitos, o algoritmo não consegue enxergar que o sistema é instável, errando a solução.

Como solução inicial, introduzimos uma perturbação na ação integrativa, com objetivo de evitar valores infinitos para cálculo do diagrama de *Nyquist* conforme a função L exposta no algoritmo 3.

4.3 A Função Robustez

A função de robustez descrita no Algoritmo 4 representa um dos problemas de otimização abordados neste trabalho, definido pela equação (3.9). Essa função é utilizada como medida de avaliação dos indivíduos da população e tem como objetivo garantir que a menor distância entre o ponto $-1 + j0$ e o diagrama de *Nyquist* de $L(j\omega)$ seja igual ao raio da circunferência M_s , um parâmetro de projeto definido na resposta em frequência.

A função L apresentada no Algoritmo 3 calcula os valores de $L(j\omega_i)$ e os armazena nos vetores Re e Im, correspondendo às partes real e imaginária de $L(j\omega_i)$, respectivamente. O vetor d é utilizado para armazenar as distâncias entre o ponto $(-1, 0)$ e os pontos ao

Figura 4.1: *Nyquist* com visão do sistema estávelFigura 4.2: *Nyquist* com visão do sistema instável

longo da curva $L(j\omega_i)$ que foram armazenados nos vetores Re e Im . Finalmente, a função de robustez é a medida de avaliação para cada indivíduo da população (que é um candidato a solução do problema de otimização) e o seu valor é utilizado na avaliação realizada pelo Algoritmo Genético (GA).

Algoritmo 3: Função L

Entrada: \mathbf{M} ; \mathbf{C} ; \mathbf{K} ; \mathbf{B} ; \mathbf{d} ; τ ; ω e *populacao***Saída:** \mathbf{L}

```

1  $K_p = \text{populacao}(1);$ 
2  $K_i = \text{populacao}(2);$ 
3  $K_d = \text{populacao}(3);$ 
4 para  $i = 1$  até  $i = \text{comprimento}(\omega)$  faça
5    $\beta = j \times \omega(i);$ 
6    $L(i) = (K_p + K_i/\beta + 0.0001) + \beta \times K_d) \times \mathbf{d} \times (\mathbf{M} \times \beta^2 + \mathbf{C} \times \beta + \mathbf{K})^{-1} \times \mathbf{B} \times e^{-\tau \times \beta};$ 
7    $i = i + 1;$ 
8 fim
```

Algoritmo 4: Função Objetivo**Entrada:** L e M_s **Saída:** robustez

- 1 $d = \sqrt{(\text{Re}(L) + 1)^2 + \text{Im}(L)^2}$;
- 2 $\text{robustez} = (\min(d) - M_s^{-1})^2$;

4.4 A Função de Restrições

O algoritmo 5 apresenta a função de restrição responsável por estabelecer as limitações do problema de otimização, definidas pelas equações (3.10). O vetor "*cross*" armazena os pontos de intersecção entre a curva de Nyquist de $L(j\omega)$ e o eixo real. A variável "*restrictions*" é utilizada para representar a restrição não linear estabelecida pela inequação (3.10) e é restrita a valores menores ou iguais a zero.

A função de restrição envia os valores de *restrictions* de volta para o Algoritmo Genético e avalia o indivíduo da população com a função fitness. A busca é concluída quando as mudanças entre as gerações se tornam insignificantes e o melhor indivíduo avaliado pelas funções descritas é apresentado como resposta. Os resultados obtidos com o algoritmo desenvolvido são apresentados no capítulo 5.

4.5 A Função de IAE

A função de integração do erro absoluto é um indicador que avalia o desempenho do sistema conforme descrito na seção 2.4. Esse indicador considera o erro do sistema, e para calculá-lo, a maneira mais simples é executar a simulação do sistema de segunda ordem que está sendo estudado.

Ao usar o MATLAB/Simulink®, uma ferramenta que simula sistemas de controle de forma mais precisa em relação a sistemas reais, é possível medir o erro do sistema considerando o atraso do mesmo, o que é um dos objetivos deste trabalho. A figura 4.3 apresenta a simulação desenvolvida que utiliza as matrizes de estado do sistema, considera o atraso e está acoplada ao controlador PID. Nessa simulação, o *IAE* é calculado e o valor resultante é salvo em uma variável com o mesmo nome.

O Pseudocódigo 6 emprega a simulação mencionada para calcular o índice *IAE* para cada indivíduo da população, sendo que cada indivíduo é composto por K_p , K_i e K_d . As demais variáveis necessárias para a execução da simulação são carregadas no *Workspace* do software MATLAB®. A função importa os parâmetros do controlador para a simulação e a executa, utilizando as variáveis do *Workspace*. Após a conclusão da simulação, a função retorna o valor do *IAE*.

Algoritmo 5: Função de Restrição

```

Entrada: L; Z;
Saída: restrictions
1 contadorcw = 0;
2 contadorccw = 0;
3 cross = 0;
4 se  $\text{Re}(L(1)) < -1 \&\& \text{abs}(\text{Im}(L(1))) < 0.2$  então
5   | xcrosses = [xcrosses Re(Ls(1))];
6   | se  $\text{Im}(L(2)) < \text{Im}(L(1))$  então
7   | | contadorccw = contadorccw + 1;
8   | fim
9   | senão
10  | | contadorcw = contadorcw + 1;
11  | fim
12 fim
13 para i = 1 até comprimento(L) - 1 faça
14   | se  $\text{Im}(L(i)) \times \text{Im}(L(i+1)) < 0$  então
15   | | se  $\text{Re}(L(i)) \times \text{Re}(L(i+1))/2 < -1$  então
16   | | | cross = [cross Re(L(i)) + Re(L(i+1))]/2];
17   | | | se  $\text{Im}(L(i+1)) < \text{Im}(L(i))$  então
18   | | | | contadorccw = contadorccw + 1;
19   | | | fim
20   | | | senão
21   | | | | contadorcw = contadorcw + 1;
22   | | | fim
23   | | fim
24   | fim
25   | i = i + 1;
26 fim
27 para i = 1 até comprimento(L) - 1 faça
28   | se  $-\text{Im}(L(\text{comprimento}(L) - (i - 1))) \times -\text{Im}(L(\text{comprimento}(L) - i)) < 0$ 
29   | | então
30   | | | se
31   | | | |  $\text{Re}(L(\text{comprimento}(L) - (i - 1))) + \text{Re}(L(\text{comprimento}(L))) / 2 < -1$ 
32   | | | | então
33   | | | | | cross = [cross Re(L(comprimento(L) - (i - 1))) + Re(L(comprimento(L) - i))]/2];
34   | | | | se
35   | | | | |  $-\text{Im}(L(\text{comprimento}(L) - (i - 1))) > -\text{Im}(L(\text{comprimento}(L) - i))$ 
36   | | | | | então
37   | | | | | | contadorccw = contadorccw + 1;
38   | | | | | fim
39   | | | | | senão
40   | | | | | | contadorcw = contadorcw + 1;
41   | | | | | fim
42   | | | fim
43   | | fim
44   | fim
45   | i = i + 1;
46 fim
47 restrictions =  $-\min(\text{cross}) \times \text{contadorcw} + (Z - \text{contadorccw})^2$ ;

```

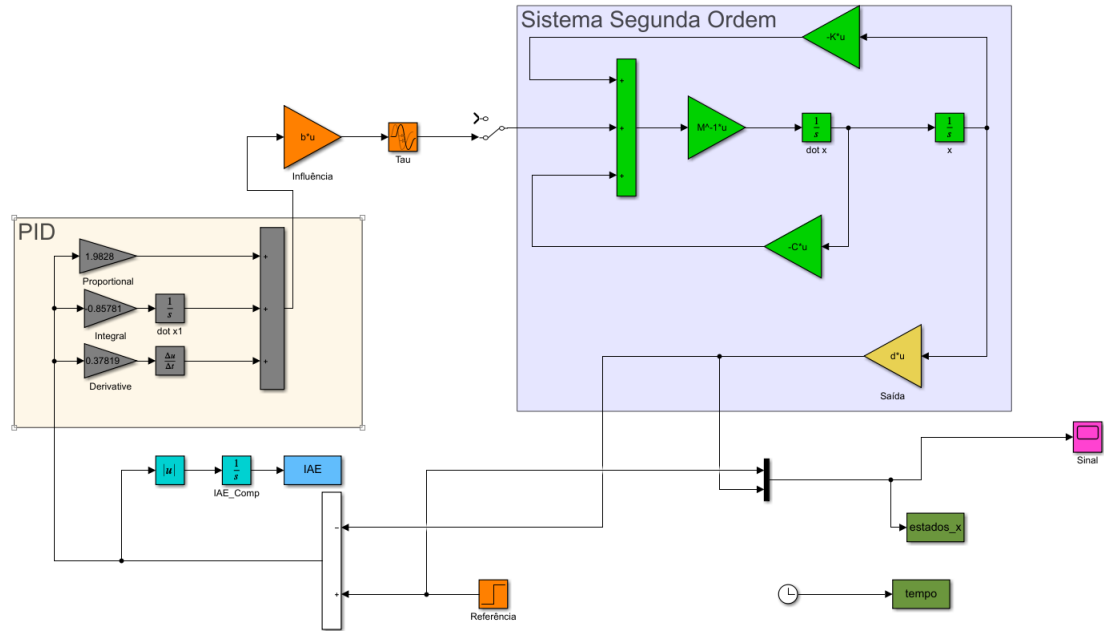


Figura 4.3: Simulação criada com MATLAB/Simulink®

4.6 A Função de *Fitness*

A função *Fitness* recebe como entrada dois parâmetros: os índices de robustez e *IAE*, resultantes das funções descritas nas seções 4.3 e 4.5, respectivamente. O índice de robustez mede o quão robusto é o sistema, ou seja, o quão improvável é que ele se torne instável. Por sua vez, o *IAE* mede a área abaixo do gráfico do erro do sistema, sendo que o erro representa a distância entre o sistema e o sinal desejado.

Entretanto, é possível notar que as definições dessas duas medidas podem entrar em conflito, já que quando se deseja minimizar o erro do sistema, ou seja, ter um tempo de acomodação baixo, pode-se acabar com um sistema menos robusto, com altos valores de *Overshoot*. Como solução, foi criado um parâmetro chamado alfa, que pondera esses dois

Algoritmo 6: Função IAE

Entrada: populacao e **simulink**

Saída: IAE

```

1 Kp = populacao(1);
2 Ki = populacao(2);
3 Kd = populacao(3);
4 setParam(strcat(simulink,"/Proportional"),"Gain",num2str(Kp));
5 setParam(strcat(simulink,"/Integral"),"Gain",num2str(Ki));
6 setParam(strcat(simulink,"/Derivative"),"Gain",num2str(Kd));
7 sim(simulink);
8 IAE = IAE(length(IAE));

```

critérios na função de fitness. O valor de alfa é um número entre zero e um, permitindo escolher se dar maior importância ao índice de robustez ou ao *IAE*, bem como decidir se ambos têm a mesma importância na otimização do algoritmo de busca. O algoritmo 7 apresenta essa lógica.

Algoritmo 7: Função Fitness

Entrada: Robustez, IAE, e alfa

Saída: ff

```
1 ff = alfa × robustez + (1 - alfa) × IAE;
```

4.7 A Função de Variabilidade

O objetivo da Função de Variabilidade Genética, apresentada no Algoritmo 8, é solucionar o problema de iteração do Algoritmo Genético quando não houver melhora no valor da Função *Fitness* após várias iterações. Com isso, evita-se a execução desnecessária do programa quando a solução estiver presa em um mínimo local, no qual não haverá avanços significativos com a continuidade das execuções do *GA*.

A função avalia o valor da função objetivo em dez execuções. Caso haja uma baixa variância entre esses valores, indica que o algoritmo não está apresentando evolução na otimização e que o custo computacional de continuar executando o algoritmo proposto neste trabalho não resultará em ganhos significativos. Com isso, a função interrompe a execução do *GA* e retorna o melhor indivíduo para aquela execução

Algoritmo 8: Função de Variabilidade

Entrada: variabilidade, evolucao, e ff

```
1 evolucao(variabilidade) = ff;
2 variabilidade = variabilidade + 1;
3 se tamanho(evolucao) > 10 então
4   |   variabilidade = 1;
5   |   evolucao = evolucao(2:end);
6   |   se var(evaluation) < 0.0000001 então
7   |   |   objetivo = "fim";
8   |   |   melhorIndividuo = populacao(1,:);
9   |   |   interromper;
10  |   fim
11 fim
```

Capítulo 5

Experimentos e Resultados

O objetivo deste estudo é analisar a eficácia do controlador PID em sistemas de segunda ordem com atraso estáveis em malha aberta. Para a otimização do PID, são utilizados dois parâmetros de busca.

A primeira otimização se baseia no critério de robustez do sistema, e seus resultados são apresentados na seção 5.2. A segunda otimização é baseada no índice de *IAE*, buscando alcançar uma maior eficiência do sistema, e seus resultados estão descritos na seção 5.3.

Podemos encontrar na seção 5.4 uma comparação entre os resultados obtidos quando otimizamos a robustez do sistema e o índice de Integral do Erro Absoluto.

Podemos inferir que esses parâmetros de avaliação do sistema são mutuamente exclusivos, o que significa que é difícil obter um sistema altamente robusto e eficiente ao mesmo tempo. Quando minimizamos o índice *IAE*, a robustez do sistema pode ser comprometida. Na seção 5.5, tentamos encontrar um equilíbrio para otimizar tanto a robustez quanto o índice de *IAE*, a fim de obter um controlador ideal que possa manter a estabilidade e o tempo de acomodação mesmo em situações de perturbações no sistema.

5.1 Experimentos estudados

ESCREVER ALGO AQUI

5.1.1 Exemplo 1

Na Figura 5.1, é apresentado um exemplo clássico de aplicação do sistema massa-mola-amortecedor de um grau de liberdade. O problema de controle por realimentação de estados é definido para $\mathbf{M} = 1$, $\mathbf{C} = 0,01$, $\mathbf{K} = 5$, $\mathbf{B} = 1$ e $\tau = 0,1$ como no Exemplo 2 de RAM et al. (2009). O objetivo é encontrar valores de \mathbf{K}_p , \mathbf{K}_i e \mathbf{K}_d , de forma que o diagrama de Nyquist de $L(j\omega)$ esteja completamente fora da área delimitada pela circunferência de raio M_s^{-1} , que é um parâmetro de projeto definido. A definição de M_s estabelece margens de ganho e de fase para o sistema, e valores comuns de M_s estão dentro do intervalo de $1,22 \leq M_s \leq 1,667$ (SKOGESTAD e POSTLETHWAITE 2007).

O método proposto neste trabalho foca nos parâmetros de projeto baseados no diagrama de Nyquist do ganho de malha do sistema $L(j\omega)$, considerando os conceitos de




Figura 5.1: Sistema massa-mola-amortecedor de um grau de liberdade

estabilidade segundo os critérios de Nyquist. O objetivo da solução é obter um sistema relativamente robusto, tendo como meta $M_s = 1,66$.

5.1.2 Exemplo 2

Considerando um exemplo prático para demonstrar a aplicação do método apresentado, conforme visto em Ram et al. (2011), podemos tomar as matrizes de massa, amortecimento e elasticidade como:

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \mathbf{C} = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}, \mathbf{K} = \begin{bmatrix} 3 & -2 \\ -2 & 3 \end{bmatrix}$$

Considerando o método apresentado em Ram et al. (2011), vamos utilizar como exemplo prático uma matriz de entradas $\mathbf{B}' = \mathbf{D}' = [0 \ 1]$ e uma constante de atraso $\tau = 5$. Nesse caso, estamos lidando com um sistema não amortecido com autovalores de malha aberta sobre o eixo imaginário do plano s . Quando isso ocorre, pode ser difícil trabalhar com a resposta em frequência, uma vez que há uma descontinuidade nas frequências que coincidem com os autovalores do sistema no eixo imaginário. Para lidar com essa situação, a literatura de sistemas de controle com base na teoria do mapeamento sugere fazer uma pequena alteração no contorno do plano s , de modo a evitar os polos sobre o eixo $j\omega$. Em outras palavras, é necessário deslocar levemente os polos para a esquerda do eixo, o que pode ser conseguido por meio de uma pequena alteração em um dos elementos da matriz de amortecimento (OGATA 2009). Nesse exemplo, a matriz \mathbf{C} é considerada.

$$\mathbf{C} = \begin{bmatrix} 1 & -0,9999 \\ -0,9999 & 1 \end{bmatrix}$$

Novamente a busca pela solução do problema descrito pela equação (3.9) é realizada para o círculo $M_s = 1,6667$.

5.1.3 Exemplo 3

Neste caso específico, foi feita uma pequena modificação do exemplo 5.1.2, com o objetivo de introduzir uma perturbação no sistema.

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \mathbf{C} = \begin{bmatrix} 1 & -0.9 \\ -0.9 & 1 \end{bmatrix}, \mathbf{K} = \begin{bmatrix} 3 & -2 \\ -2 & 3 \end{bmatrix}$$

Para uma matriz de entradas $\mathbf{B}' = \mathbf{D}' = [0 \ 1]$, e uma constante de atraso $\tau = 0,5$.

5.2 Resultados da Otimização de Robustez

O método apresentado aqui trata dos parâmetros de design com base no gráfico de Nyquist da função de transferência em malha aberta do sistema $L(j\omega)$. Ele utiliza os critérios de estabilidade de Nyquist para alcançar uma solução que satisfaça um sistema razoavelmente robusto, com a circunferência $M_s = 1,6667$.

Os valores dos vetores de ganho descobertos utilizando o algoritmo genético (método proposto) com atraso estão apresentados na Tabela 5.1.

Exemplo	kp	ki	kd	robustez
1	1,4160	1,5225	0,8718	0,1536
2	0,1774	0,2229	0,4433	0,0001
3	-0,2400	1,0990	1,6015	0,3148

Tabela 5.1: Tabela de Ganhos do PID - Otimização de Robustez

5.2.1 Resultado exemplo 1

Ao aplicar o algoritmo genético ao 5.1.1 e definir a robustez como parâmetro de otimização, a Figura 5.2 é gerada. É possível observar que o diagrama está tangente à circunferência M_s^{-1} , que tem como objetivo garantir a robustez do sistema.




Figura 5.2: Diagrama de Nyquist Exemplo 5.1.1

A Figura 5.3 apresenta uma simulação que demonstra um sistema estável e robusto, de acordo com a teoria descrita na seção 2.5, a qual utiliza o diagrama de *Nyquist*.




Figura 5.3: Simulação do Sistema do Exemplo 5.1.1

5.2.2 Resultado exemplo 2

Ao considerar o exemplo 5.1.2, que envolve um sistema mais complexo, a Figura 5.4 mostra o diagrama de Nyquist, que também evidencia a robustez do sistema. Isso é possível observar pelo fato do diagrama não incluir o ponto $-1 + j0$.




Figura 5.4: Diagrama de Nyquist Exemplo 5.1.2

Utilizando um valor de $\tau = 5$, foi possível obter uma medida de robustez mais flexível. Ao comparar com os resultados do trabalho anterior (DANTAS 2019), a resposta simulada mostrada na Figura 5.5 apresentou um tempo de acomodação médio de sessenta segundos,




Figura 5.5: Simulação do Sistema do Exemplo 5.1.2

sendo que, para este trabalho, o sinal de referência foi definido no nível um. Já no trabalho de (DANTAS 2019), o sinal de referência foi definido em zero.

5.2.3 Resultado exemplo 3

No exemplo 5.1.3, houve uma alteração na matriz C em relação ao exemplo 5.1.2. O gráfico de Nyquist resultante é apresentado na Figura 5.6, evidenciando a robustez do sistema de segunda ordem com atraso. A simulação do sistema no exemplo 5.1.3 foi realizada no MATLAB/Simulink®, e o tempo de acomodação foi ainda mais reduzido, em torno de trinta segundos, conforme evidenciado na Figura 5.7.

5.3 Resultados da Otimização de IAE

Os resultados da otimização com o índice Integral do Erro Absoluto são apresentados neste trecho, em comparação aos resultados teóricos discutidos na seção 5.2. Espera-se que essa abordagem resulte em um desempenho mais eficiente, com um tempo de acomodação reduzido, uma vez que não é necessário que o sistema de controle seja robusto. No entanto, o critério de estabilidade de *Nyquist* ainda foi usado para garantir a estabilidade do sistema, com a circunferência $M_s = 1,6667$. A Tabela 5.2 fornece os valores dos ganhos obtidos pelo algoritmo genético.

5.3.1 Resultado exemplo 1

Utilizando o algoritmo genético (GA), foi realizada a otimização do índice *IAE* por meio de simulação computacional do exemplo 5.1.1. Como resultado, o gráfico 5.8 de-




Figura 5.6: Diagrama de Nyquist Exemplo 5.1.3




Figura 5.7: Simulação do Sistema do Exemplo 5.1.3

Exemplo	kp	ki	kd	IAE
1	1,5467	4,7074	2,8071	1,0622
2	0,5146	0,2539	0,4016	7,3368
3	1,7283	1,0606	1,9955	2,2072

Tabela 5.2: Tabela de Ganhos do PID - Otimização de IAE

monstrou que o sistema não deve obrigatoriamente tangenciar a circunferência que representa a sua robustez.




Figura 5.8: Diagrama de Nyquist Exemplo 5.1.1




Figura 5.9: Simulação do Sistema do Exemplo 5.1.1

Ao examinarmos o gráfico 5.9, podemos notar que o sistema alcança o estado estacionário em poucos segundos, com um tempo de acomodação menor do que o apresentado na seção 5.2, o que é um resultado desejado neste projeto.

5.3.2 Resultado exemplo 2

No exemplo 5.1.2, que é mais complexo e exigiu mais esforço para encontrar uma solução adequada, a Figura 5.10 mostra que o diagrama passa pela circunferência M_s , o que não torna o sistema instável, como indicado pela simulação na Figura 5.11. No entanto,

a otimização da Integral do Erro Absoluto tornou o sistema mais eficiente, apresentando menor *overshoot* e tempo de acomodação.




Figura 5.10: Diagrama de Nyquist Exemplo 5.1.2




Figura 5.11: Simulação do Sistema do Exemplo 5.1.2

5.3.3 Resultado exemplo 3

Através da otimização desse parâmetro no exemplo 5.1.3, foi possível observar que o *Nyquist* na Figura 5.12 se afastou mais da circunferência de robustez. Na Figura 5.13, que apresenta o resultado da simulação do sistema para esse exemplo, pode-se notar que

o tempo de acomodação é menor em comparação à busca pela robustez apresentada na seção 5.2.3 e até mesmo no trabalho original (DANTAS 2019).




Figura 5.12: Diagrama de Nyquist Exemplo 5.1.3




Figura 5.13: Simulação do Sistema do Exemplo 5.1.3

5.4 Resultados da Comparação entre os parâmetros de otimização

Nesta seção, faremos uma análise comparativa dos parâmetros otimizados diretamente e observaremos os benefícios de realizar a busca pelo critério de robustez ou pelo índice de *IAE*. A ideia inicial é comparar os gráficos de *Nyquist* e as simulações do sistema, sobrepondo os resultados. Além disso, realizaremos uma simulação com perturbação no sistema para validar sua robustez.

Com o objetivo de comparar os ganhos resultantes de cada parâmetro otimizado, efetuamos o cálculo da variância entre o ganho obtido a partir da otimização da robustez e aquele proveniente do índice que considera o módulo do erro. Os resultados dessa comparação foram apresentados na Tabela 5.3, permitindo-nos avaliar como cada um desses parâmetros afeta os ganhos.

Exemplo	Δk_p	Δk_i	Δk_d	Robustez	IAE
1	0.0085	5,0717	1,8727	0,1536	1,0622
2	0,0569	0,0004	0,0008	0,0001	7,3368
3	1,9370	0,0007	0,0776	0,3148	2,2072

Tabela 5.3: Tabela de Variança dos Ganhos do PID - Comparação da Otimização de *IAE* com robustez

Após analisar a Tabela 5.3, é perceptível que no exemplo 5.1.2, a variação nos ganhos é baixa, o que era esperado devido ao comportamento semelhante no diagrama de *Nyquist*. No entanto, para os exemplos 5.1.1 e 5.1.3, há uma variação maior, especialmente no ganho integral e proporcional.

5.4.1 Resultado exemplo 1

A Figura 5.14 apresenta a comparação dos diagramas para o exemplo 5.1.1, sendo que o diagrama que enfatiza a robustez do sistema tangencia a referência M_s , enquanto que o diagrama otimizado para o *IAE* está próximo à circunferência e apresenta comportamento semelhante a outro diagrama.

A respeito da Figura 5.15, percebemos que o sistema estabilizado pelo critério do *IAE* é mais eficiente, apresentando um tempo de acomodação mais rápido, enquanto o sistema com ênfase na robustez tem uma resposta transitória mais lenta.

5.4.2 Resultado exemplo 2

No caso do exemplo 5.1.2, por se tratar de um sistema mais complexo e, teoricamente, com maior dificuldade na sintonia dos ganhos do controlador, a Figura 5.16 apresenta o diagrama de *Nyquist*. Neste caso, é possível observar que, para o índice considerado, o *Nyquist* intersecta a circunferência, enquanto que, para a busca pela robustez, isso não ocorre, como esperado. Além disso, conseguimos obter um comportamento semelhante no diagrama, circulando o ponto $0 + 0j$.

5.4. RESULTADOS DA COMPARAÇÃO ENTRE OS PARÂMETROS DE OTIMIZAÇÃO43




Figura 5.14: Comparação do diagrama de *Nyquist* do Exemplo 5.1.1




Figura 5.15: Comparação da simulação do Sistema do Exemplo 5.1.1

A simulação do sistema na Figura 5.17 apresenta o comportamento desejado quando otimizado com o índice de Integral do Erro Absoluto, sendo notável que o sistema é mais eficiente, enquanto que o sistema otimizado com ênfase na robustez tem uma resposta transitória mais lenta.

5.4.3 Resultado exemplo 3

No exemplo 5.1.3, podemos observar na Figura 5.18 que há uma maior distância do diagrama em relação a ambas as otimizações. A partir da simulação do sistema na F5.19,



Figura 5.16: Comparação do diagrama de *Nyquist* do Exemplo 5.1.2

Figura 5.17: Comparação da simulação do Sistema do Exemplo 5.1.2

verificamos que a otimização do índice de *IAE* apresentou um tempo de acomodação menor em comparação com a otimização do critério de robustez.

5.5 Resultados da Concorrência entre os parâmetros de otimização

Na seção de resultados, iremos examinar os resultados conseguidos com a função de *fitness* definida na seção 4.6, que tenta considerar os dois parâmetros de busca. Nesse

5.5. RESULTADOS DA CONCORRÊNCIA ENTRE OS PARÂMETROS DE OTIMIZAÇÃO




Figura 5.18: Comparação do diagrama de *Nyquist* do Exemplo 5.1.3




Figura 5.19: Comparação da simulação do Sistema do Exemplo 5.1.3

caso, estamos atribuindo a mesma importância à robustez e ao *IAE*, já que o valor do parâmetro α é 0,5.

Usando essa abordagem, é possível encontrar um equilíbrio que mantenha a robustez do sistema ao mesmo tempo que melhora o desempenho, reduzindo o tempo de acomodação. Os ganhos do controlador PID para esse método podem ser observados na Tabela 5.4.

Exemplo	k_p	k_i	k_d	Robustez	IAE	ff
1	2,9222	5,4647	3,6449	0,0073	0,9149	0,4611
2	0,5145	0,2578	0,4004	0,0041	7,3408	3,6725
3	0,4372	0,7548	1,8163	0,4856	2,4390	1,4623

Tabela 5.4: Tabela de Ganhos do PID com Método proposto - Comparação da Otimização de IAE com robustez

5.5.1 Resultado exemplo 1

A Figura 5.20 revela que, para o exemplo 5.1.1, o diagrama de Nyquist apresenta uma pequena distância da referência M_s , mantendo sinais de um sistema mais robusto, sem perder a prioridade da eficiência. Essa situação difere da Figura 5.8, onde o diagrama tende a se afastar ainda mais do raio de robustez estabelecido.

Analizando a Figura 5.21, percebe-se que a combinação dos parâmetros resulta em uma melhoria geral em relação à simulação em que a busca tentou otimizar apenas o índice IAE, como evidenciado na Figura 5.9, e também em comparação com a simulação do trabalho base (DANTAS 2019).




Figura 5.20: Diagrama de Nyquist com Método proposto do Exemplo 5.1.1

5.5.2 Resultado exemplo 2

No caso do exemplo 5.1.2, que apresenta maior complexidade, nota-se que o gráfico de Nyquist na Figura 5.22 está próximo à circunferência de robustez M_s , e os resultados da simulação mostram eficiência, conforme evidenciado na Figura 5.23. Esses resultados são superiores aos obtidos nas simulações em que é otimizado apenas um parâmetro na busca do algoritmo GA.

5.5. RESULTADOS DA CONCORRÊNCIA ENTRE OS PARÂMETROS DE OTIMIZAÇÃO47




Figura 5.21: Simulação do Sistema com Método proposto do Exemplo 5.1.1




Figura 5.22: Diagrama de *Nyquist* com Método proposto do Exemplo 5.1.2

5.5.3 Resultado exemplo 3

Nesta variação do exemplo 5.1.2, introduzimos uma perturbação no sistema para simular um sistema não robusto. Na Figura 5.25, podemos observar que a resposta transitória do sistema é menor em comparação com as simulações realizadas nas seções anteriores, onde a otimização foi realizada em apenas um dos parâmetros. Na Figura 5.22, a curva de Nyquist não se afasta muito da circunferência, o que indica que o sistema de controle continua eficiente em termos de robustez e tempo de acomodação, que são importantes para bons resultados em sistemas de controle (OGATA 2009).




Figura 5.23: Simulação do Sistema com Método proposto do Exemplo 5.1.2




Figura 5.24: Diagrama de *Nyquist* com Método proposto do Exemplo 5.1.3




Figura 5.25: Simulação do Sistema com Método proposto do Exemplo 5.1.3

Capítulo 6

Conclusão

Diante do que foi abordado até o momento, é notória a importância de estudos voltados para a área de processos industriais, por meio da realização de um controle robusto, é possível obter uma maior confiabilidade na operação das plantas industriais nos quesitos de aumentar a segurança operacional e a confiabilidade na redução do número de paradas inesperadas. Nas indústrias na atualidade, é comum utilizar os controladores do tipo PID para o controle das válvulas de alimentação de água e o controle da vazão de vapor, majoritariamente pela sua facilidade de aplicação. Porém, apesar da facilidade de uso, a sintonia desse tipo de controle depende diretamente da carga operacional da planta e para usos quando o sistema não apresenta atraso significativo, quando o sistema tem atraso e sintonia dos ganhos do controlador se torna um para indústria.

Neste trabalho foram apresentadas soluções solucionar esses gargalos na indústria para o controle de sistemas de segunda ordem com atraso utilizando Controlador PID. A utilização da representação dos sistemas de segunda ordem com atraso por matriz de receptância permite que o modelo seja obtido de maneira experimental, o que em casos de sistemas com maior complexidade torna-se uma alternativa muito desejada. O problema de controle foi formulado matematicamente como um problema de otimização para a obtenção dos vetores de ganho do controlador PID. O objetivo de respeitar o critério de projeto definido, de não interceptar o círculo M_s , garantindo estabilidade robusta, também adicionamos um critério de restrição mais rígido, para que a curva de Nyquist tangencie $L(j\omega)$ com a circunferência M_s ,

Dessa forma, é esperado com o desenvolvimento do restante do trabalho a modelagem e sintonia dos controladores PID aplicados a sistema de segunda ordem com atraso, otimizados por meio do uso de Meta-heurística para encontrar os ganhos que satisfaz nossa restrição do projeto baseado no critério de estabilidade de Nyquist, além de aplicar esse método a sistema de controle instáveis e avaliar seu desempenho também essa solução para sistema multivariáveis com atraso com isso, é desejado obter resultados satisfatórios para o controle desses sistemas.

Referências Bibliográficas

aaa (n.d.a).

aaa (n.d.b).

aaa (n.d.c).

ARAÚJO, José Mário (2018), ‘Partial eigenvalue assignment in linear time-invariant systems using state-derivative feedback and a left eigenvectors parametrization’, *Proceedings of the Institution of Mechanical Engineers, Part I: Journal of Systems and Control Engineering* p. 0959651818811010.

ARAÚJO, José Mário e Tito Luís Maia SANTOS (2018), ‘Control of a class of second-order linear vibrating systems with time-delay: Smith predictor approach’, *Mechanical Systems and Signal Processing* **108**, 173–187.

BALAS, Mark (1982), ‘Trends in large space structure control theory: fondest hopes, wildest dreams’, *IEEE Transactions on Automatic Control* **27**(3), 522–535.

DANTAS, N. J. B. (2019), Projeto de controladores para sistemas de segunda ordem com atraso via resposta em frequência., Dissertação (mestrado) — mestrado em engenharia mecânica, Universidade Federal do Rio Grande do Norte, Natal.

DANTAS, Nelson J.B., Carlos E.T. Dórea e José M. Araújo (2020), ‘Design of rank-one modification feedback controllers for second-order systems with time delay using frequency response methods’, *Mechanical Systems and Signal Processing* **137**, 106404. Special issue on control of second-order vibrating systems with time delay.

URL: <https://www.sciencedirect.com/science/article/pii/S0888327019306259>

DATTA, Biswa (2004), *Numerical methods for linear control systems*, Vol. 1, Academic Press.

EUZÉBIO, Thiago AM e Péricles R BARROS (2015), ‘Iterative procedure for tuning decentralized pid controllers’, *IFAC-PapersOnLine* **48**(8), 1180–1185.

EUZÉBIO, Thiago Antonio Melo e Péricles Rezende BARROS (2013), ‘Optimal integral gain for smooth pi control’, *IFAC Proceedings Volumes* **46**(11), 529–533.

FRANKLIN, Gene F, J David Powell e Abbas Emami-Naeini (2013), *Sistemas de controle para engenharia*, Bookman Editora.

Goldberg, David E e John H Holland (1988), ‘Genetic algorithms and machine learning’, *Machine learning* **3**(2), 95–99.

GOLUB, Gene H e Charles F VAN LOAN (2012), *Matrix computations*, Vol. 3, JHU Press.

GONTIJO, Danielle S, José M Araújo, Tito LM SANTOS e Fernando O Souza (2022), ‘Proportional-integral-derivative-acceleration robust controllers for vibrating systems’, *Journal of Vibration and Control* p. 10775463211060898.

Hespanha, Joao P (2018), *Linear systems theory*, Princeton university press.

LIU, Hao e YONGXIN YUAN (2016), ‘A multi-step method for partial quadratic pole assignment problem with time delay’, *Applied Mathematics and computation* **283**, 29–35.

MARTINS, José KEC, Fábio MU Araújo e Carlos ET Dórea (2020), Um método baseado em otimização para sintonia de controladores pi para sistemas sujeitos a restrições, em ‘Congresso Brasileiro de Automática-CBA’, Vol. 2.

MathWorks (2019), ‘Genetic algorithm - MATLAB & Simulink’.

URL: <https://www.mathworks.com/help/gads/genetic-algorithm.html>

MOTTERSHEAD, John E e Yitshak M RAM (2007), ‘Receptance method in active vibration control’, *AIAA journal* **45**(3), 562–567.

NUNES, Leonardo Araújo (2022), Controle por realimentação derivativa para sistemas dinâmicos de segunda ordem com atraso, Dissertação (mestrado) — mestrado em engenharia mecatrônica, Universidade Federal do Rio Grande do Norte, Natal.

OGATA, Katsuhiko (2009), *Modern control engineering*, Prentice Hall Upper Saddle River, NJ.

RAM, YM, Akshay Singh e John E MOTTERSHEAD (2009), ‘State feedback control with time delay’, *Mechanical Systems and Signal Processing* **23**(6), 1940–1945.

Ram, YM, JE Mottershead e M Ghandchi TEHRANI (2011), ‘Partial pole placement with time delay in structures using the receptance and the system matrices’, *Linear Algebra and its Applications* **434**(7), 1689–1696.

SANTOS, Tito LM, José Mário Araújo e Taniel S Franklin (2018), ‘Receptance-based stability criterion for second-order linear systems with time-varying delay’, *Mechanical Systems and Signal Processing* **110**, 428–441.

SKOGESTAD, Sigurd e Ian POSTLETHWAITE (2007), *Multivariable feedback control: analysis and design*, Vol. 2, Wiley New York.

SOUZA, J. H. A.; CARVALHO, E. J. F. (2020), ‘Implementação e avaliação de algoritmos genéticos e de enxame no ajuste de campos de força em dinâmica molecular’, XXXI Congresso de Iniciação Científica e Tecnológica da UFRN - eCICT 2020 pp. 1604–1605.

Tehrani, Maryam Ghandchi, Robin NR Elliott e John E Mottershead (2010), ‘Partial pole placement in structures by the method of receptances: theory and experiments’, *Journal of Sound and Vibration* **329**(24), 5017–5035.

VAN LOAN, Charles F e Gene H GOLUB (1983), *Matrix computations*, Johns Hopkins University Press.

VANDERVELDE, Wallace E (1986), ‘Control of large flexible space structures’.